Univerzitet u Kragujevcu

Prirodno-Matematički fakultet

Institut za matematiku i informatiku

NYC Property Sales

Seminarski rad iz predmeta Uvod u nauku o podacima

Profesor:

Branko Arsić

Tim:

Janko Jošović 58/2022

Mihailo Golubović 42/2022

Contents

Uvod 3
Opis problema i motivacija 3
Opis i priprema podataka 4
Izvor podataka 4
Čišćenje i obrada podataka 7
Nedostajuće vrednosti 7
Konverzija tipova podataka 17
Analiza target kolone 19
Univarijantna analiza i analiza outliera 21
Bivarijantna analiza 33
Multivarijantna analiza 42
Imputacija vrednosti 44
Eksplorativna analiza podataka (EDA) 46
Feature engineering i feature selection 62
Feature engineering 62
Feature selection 69
Implementacija i procena modela 70
Zaključak 79

Uvod

Predviđanje cena nekretnina je od velike važnosti u našem vremenu, bilo da se radi o kupcu, prodavcu, investitoru ili banci. Posebno zanimljivo je predviđanje cena na velikim i dinamičnim tržištima kao što je Njujork gde se vrednost nekretnina izuzetno menja pod uticajem lokacije, tipa objekta, veličine, starosti objekta i brojnih drugih faktora. Kvalitetno predviđena cena kupcima smanjuje mogućnost preplaćivanja nekretnine i omogućava da prepoznaju pravu tržišnu vrednost, prodavcima pomaže da postave realne cene za svoje objekte uz to da cene budu konkurentne, dok investitori lako mogu da procene koje lokacije su isplative za njihova ulaganja.

Nekada je procena cene nekretnina često bila stvar iskustva i intuicije gde agent pogleda par sličnih prodaja, uzme u obzir lokaciju i stanje objekta i na osnovu toga napravi procenu. Međutim, na tržištu kao što je Njujork to često nije dovoljno, jer i male razlike (npr. ulica, sprat, godina izgradnje ili tip zgrade) mogu dosta da promene cenu. Zato se danas koriste podaci o velikom broju prethodnih prodaja i karakteristika nekretnina, kako bi se kroz analizu podataka došlo do brže, realnije i objektivnije procene vrednosti.

Za izradu ovog projekta korišćen je programski jezik R kao kvalitetan alat za izvršavanje statističkih analiza, obrađivanje podataka i vizuelizaciju rezultata. Jedne od njegovih istaknutih karakteristika su te što je koristan za konstruisanje različitih modela za predikciju i rad sa regresionim analizama, kao i veoma lako prikazivanje odgovarajućih rezultata u formi grafova što je od velike važnosti za problem predviđanja cena nekretnina.

Opis problema i motivacija

Analizom podataka o prodajama u Njujorku je cilj da napravimo model za preciznu predikciju prodajne cene nekretnine. Pošto cena predstavlja numeričku vrednost, radi se o regresionom problemu, gde je ciljna promenljiva prodajna cena, a ulazne promenljive su različite karakteristike objekta (lokacija, tip zgrade, površina, broj jedinica, godina izgradnje itd.).

Pored samog predviđanja, važan deo motivacije je primećivanje određenih trendova na tržištu kao i razumevanje koji faktori najviše utiču na cenu. Kroz analizu podataka primetićemo da li je lokacija presudna, koliko doprinosi veličina, kakav efekat ima godina izgradnje ili tip objekta, i da li postoje specifične kategorije nekretnina koje se ponašaju drugačije od ostalih.

U ovom projektu koristimo NYC Property Sales skup podataka koji predstavlja evidenciju prodaja nekretnina (zgrada ili pojedinačnih jedinica poput stanova) na tržištu Njujorka u toku približno jedne godine (septembar 2016 – septembar 2017).

Zadatak našeg projekta je razvijanje robusnog modela koji precizno predviđa prodajnu cenu nekretnine (SALE.PRICE) kao i upoređivanje performansi različitih modela mašinskog učenja sa ciljem pronalaženja onog koji je najprecizniji u svojim predikcijama.

Opis i priprema podataka

Izvor podataka

Za izradu ovog projekta korišćen je skup podataka sa Kaggle platforme NYC Property Sales. Ovaj skup podataka predstavlja evidenciju prodaja nekretnina na tržištu Njujorka tokom perioda između septembra 2016. i septembra 2017. godine. Skup sadrži oko 84 hiljade zabeleženih prodaja i 21 kolonu, pri čemu svaki red odgovara jednoj prodaji, dok kolone opisuju karakteristike nekretnine i transakcije.

Nakon što smo učitali podatke, pomoću funkcije str proveravamo strukturu atributa. Možemo uočiti da imamo ukupno 22 atributa, od čega je 11 atributa znakovnog tipa (chr), 10 atributa numeričkog tipa (int) i 1 atribut logickog tipa (logical).

```
str(data)
```

```
## 'data.frame':    84548 obs. of  22 variables:
##  $ X                             : int  4 5 6 7 8 9 10 11 12 13 ...
##  $ BOROUGH                       : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ NEIGHBORHOOD                  : chr  "ALPHABET CITY" "ALPHABET CITY" "A
LPHABET CITY" "ALPHABET CITY" ...
##  $ BUILDING.CLASS.CATEGORY       : chr  "07 RENTALS - WALKUP APARTMENTS
" "07 RENTALS - WALKUP APARTMENTS             " "07 RENTALS - WALKUP APARTMEN
TS             " "07 RENTALS - WALKUP APARTMENTS             " ...
##  $ TAX.CLASS.AT.PRESENT          : chr  "2A" "2" "2" "2B" ...
```

```
##  $ BLOCK                         : int  392 399 399 402 404 405 406 407 37
9 387 ...
##  $ LOT                           : int  6 26 39 21 55 16 32 18 34 153 ...
##  $ EASE.MENT                     : logi  NA NA NA NA NA NA ...
##  $ BUILDING.CLASS.AT.PRESENT     : chr  "C2" "C7" "C7" "C4" ...
##  $ ADDRESS                       : chr  "153 AVENUE B" "234 EAST 4TH   STR
EET" "197 EAST 3RD   STREET" "154 EAST 7TH STREET" ...
##  $ APARTMENT.NUMBER              : chr  " " " " " " " " ...
##  $ ZIP.CODE                      : int  10009 10009 10009 10009 10009 1000
9 10009 10009 10009 10009 ...
##  $ RESIDENTIAL.UNITS             : int  5 28 16 10 6 20 8 44 15 24 ...
##  $ COMMERCIAL.UNITS              : int  0 3 1 0 0 0 0 2 0 0 ...
##  $ TOTAL.UNITS                   : int  5 31 17 10 6 20 8 46 15 24 ...
##  $ LAND.SQUARE.FEET              : chr  "1633" "4616" "2212" "2272" ...
##  $ GROSS.SQUARE.FEET             : chr  "6440" "18690" "7803" "6794" ...
##  $ YEAR.BUILT                    : int  1900 1900 1900 1913 1900 1900 1920
1900 1920 1920 ...
##  $ TAX.CLASS.AT.TIME.OF.SALE     : int  2 2 2 2 2 2 2 2 2 2 ...
##  $ BUILDING.CLASS.AT.TIME.OF.SALE: chr  "C2" "C7" "C7" "C4" ...
##  $ SALE.PRICE                    : chr  "6625000" " -  " " -  " "3936272"
...
##  $ SALE.DATE                     : chr  "2017-07-19 00:00:00" "2016-12-14
00:00:00" "2016-12-09 00:00:00" "2016-09-23 00:00:00" ...
```

U nastavku se nalazi spisak atributa i kratak opis za svaki:

1. X – redni broj. Obično se briše jer nije informativno obeležje.
2. BOROUGH – opština u kojoj je nekretnina (Manhattan-1, Bronx-2, Brooklyn-3, Queens-4, Staten Island-5).
3. NEIGHBORHOOD – naziv naselja.
4. BUILDING.CLASS.CATEGORY – šira kategorija tipa/namene objekta (da se lakše grupišu slične nekretnine, npr. “One Family Homes”, “Condo”, itd.).
5. TAX.CLASS.AT.PRESENT – poreska klasa nekretnine (1–4) u trenutku kada je data set pravljen; određuje se prema upotrebi nekretnine.
6. BLOCK – poreski blok. NYC koristi Borough–Block–Lot (BBL) sistem identifikacije.
7. LOT – poreski “lot”, pododeljak bloka; predstavlja jedinstvenu parcelu unutar bloka.
8. EASE.MENT – službenost tj. pravo ograničenog korišćenja tuđe nepokretnosti (npr. pravo prolaza, infrastruktura).
9. BUILDING.CLASS.AT.PRESENT – klasa objekta u trenutku kada je data set pravljen (slovo+broj); opisuje konstruktivnu vrstu objekta.
10. ADDRESS – adresa nekretnine.
11. APARTMENT.NUMBER – broj stana/jedinice.
12. ZIP.CODE – poštanski broj.

13. RESIDENTIAL.UNITS – broj stambenih jedinica u objektu.
14. COMMERCIAL.UNITS – broj poslovnih jedinica u objektu.
15. TOTAL.UNITS – ukupan broj jedinica (stambene + poslovne).
16. LAND.SQUARE.FEET – površina zemljišta u kvadratnim stopama (sq ft).
17. GROSS.SQUARE.FEET – ukupna bruto površina objekta (svi spratovi) u sq ft.
18. YEAR.BUILT – godina izgradnje objekta.
19. TAX.CLASS.AT.TIME.OF.SALE – poreska klasa (1–4) u trenutku prodaje (može se razlikovati od "AT PRESENT").
20. BUILDING.CLASS.AT.TIME.OF.SALE – building class kod u trenutku prodaje (može se razlikovati od "AT PRESENT").
21. SALE.PRICE – prodajna cena nekretnine izražena u američkim dolarima. (**ciljna promenljiva**)
22. SALE.DATE – datum prodaje.

Mapa Njujorka

U R postoji jedan lep nacin da se prikažu mape sa korisnim podacima, a to je uz pomoć paketa sf i tigris.

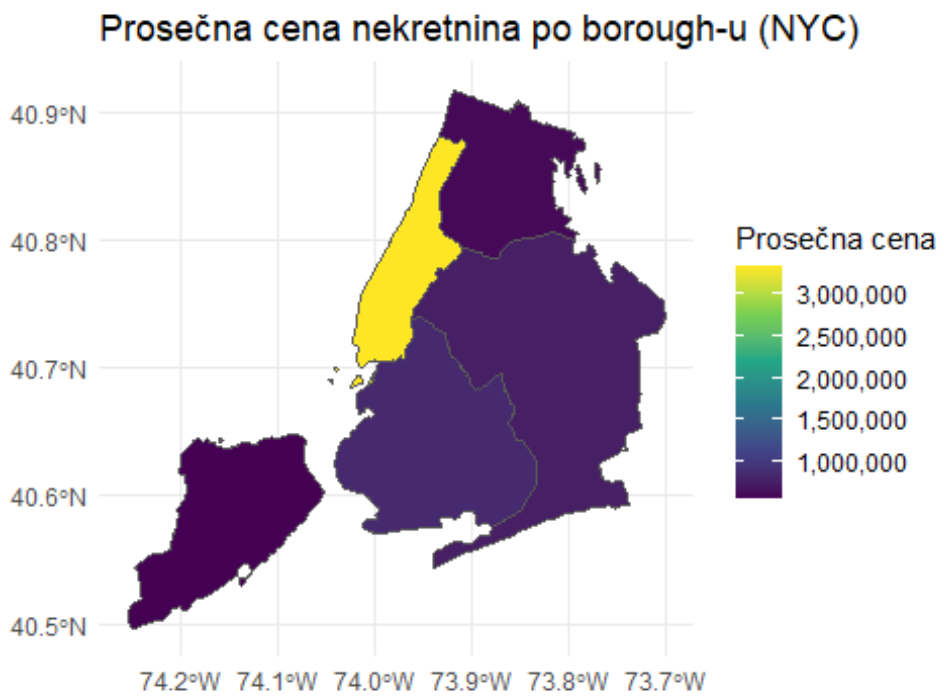

Ovim grafikom mozemo da primetimo da Menhetn prednjači sa cenama nekretnina.

Čišćenje i obrada podataka

Čišćenje podataka predstavlja proces prepoznavanja i uklanjanja nepravilnosti u skupu podataka, sa ciljem dobijanja pouzdanih i konzistentnih informacija za dalju analizu. Ovaj proces obuhvata obradu nedostajućih vrednosti, konverziju tipova podataka, uklanjanje nelogičnih i ekstremnih vrednosti, kao i proveru konzistentnosti atributa.

Prva stvar koja se može uočiti prilikom pregleda skupa podataka jeste postojanje kolone X, koja predstavlja redni broj zapisa koji je nastao prilikom eksportovanja podataka u CSV format. S obzirom na to da ne predstavlja stvarno obeležje nekretnine ova kolona se treba ukloniti.

Pošto je to prva kolona to radimo na ovaj način.

```
data <- data[, -1]
```

Nedostajuće vrednosti

Ovom linijom koda proveravamo u kojim kolonama imamo NA vrednosti:

```
colSums(is.na(data))

##                        BOROUGH                    NEIGHBORHOOD
##                              0                               0
##        BUILDING.CLASS.CATEGORY           TAX.CLASS.AT.PRESENT
##                              0                               0
##                          BLOCK                             LOT
##                              0                               0
##                      EASE.MENT      BUILDING.CLASS.AT.PRESENT
##                          84548                               0
##                        ADDRESS                APARTMENT.NUMBER
##                              0                               0
##                       ZIP.CODE               RESIDENTIAL.UNITS
##                              0                               0
##                COMMERCIAL.UNITS                    TOTAL.UNITS
##                              0                               0
##                LAND.SQUARE.FEET               GROSS.SQUARE.FEET
##                              0                               0
##                      YEAR.BUILT      TAX.CLASS.AT.TIME.OF.SALE
##                              0                               0
## BUILDING.CLASS.AT.TIME.OF.SALE                     SALE.PRICE
##                              0                               0
##                      SALE.DATE
##                              0
```

Proverom nedostajućih vrednosti utvrđeno je da su sve kolone popunjene, osim kolone EASE.MENT koja sadrži isključivo NA vrednosti. Verovatno je prilikom unosa podataka za

ostale atribute korišćena druga oznaka za izostavljene vrednosti. Kako EASE.MENT ne sadrži nijednu korisnu informaciju, ova kolona je uklonjena iz skupa podataka.

```
data$EASE.MENT <- NULL
```

Sada treba proveriti “lažne null“ vrednosti. Ako pogledamo prvih 10 redova preko head() funkcije vidimo da se u kolonama APARTMENT.NUMBER i SALE.PRICE nalaze vrednosti “-” i “ ” gde bi trebalo da budu numeričke vrednosti tako da su one verovatno korišćene umesto NA vrednosti.

```
head(data)

##   BOROUGH  NEIGHBORHOOD                     BUILDING.CLASS.CATEGORY
## 1       1 ALPHABET CITY 07 RENTALS - WALKUP APARTMENTS
## 2       1 ALPHABET CITY 07 RENTALS - WALKUP APARTMENTS
## 3       1 ALPHABET CITY 07 RENTALS - WALKUP APARTMENTS
## 4       1 ALPHABET CITY 07 RENTALS - WALKUP APARTMENTS
## 5       1 ALPHABET CITY 07 RENTALS - WALKUP APARTMENTS
## 6       1 ALPHABET CITY 07 RENTALS - WALKUP APARTMENTS
##   TAX.CLASS.AT.PRESENT BLOCK LOT BUILDING.CLASS.AT.PRESENT
## 1                   2A   392   6                        C2
## 2                    2   399  26                        C7
## 3                    2   399  39                        C7
## 4                   2B   402  21                        C4
## 5                   2A   404  55                        C2
## 6                    2   405  16                        C4
##                  ADDRESS APARTMENT.NUMBER ZIP.CODE RESIDENTIAL.UNITS
## 1           153 AVENUE B                     10009                 5
## 2  234 EAST 4TH   STREET                     10009                28
## 3  197 EAST 3RD   STREET                     10009                16
## 4    154 EAST 7TH STREET                     10009                10
## 5 301 EAST 10TH   STREET                     10009                 6
## 6 516 EAST 12TH   STREET                     10009                20
##   COMMERCIAL.UNITS TOTAL.UNITS LAND.SQUARE.FEET GROSS.SQUARE.FEET YEAR.BUI
LT
## 1                0           5             1633              6440       19
00
## 2                3          31             4616             18690       19
00
## 3                1          17             2212              7803       19
00
## 4                0          10             2272              6794       19
13
## 5                0           6             2369              4615       19
00
## 6                0          20             2581              9730       19
00
##   TAX.CLASS.AT.TIME.OF.SALE BUILDING.CLASS.AT.TIME.OF.SALE SALE.PRICE
## 1                         2                             C2    6625000
```

```
## 2                          2                                C7         -
## 3                          2                                C7         -
## 4                          2                                C4   3936272
## 5                          2                                C2   8000000
## 6                          2                                C4         -
##             SALE.DATE
## 1 2017-07-19 00:00:00
## 2 2016-12-14 00:00:00
## 3 2016-12-09 00:00:00
## 4 2016-09-23 00:00:00
## 5 2016-11-17 00:00:00
## 6 2017-07-20 00:00:00
```

Proveravamo u kojim se kolonama i koliko javlja nedostajuća vrednost u vidu praznog stringa.

```r
colSums(data == " ")
```

```
##                       BOROUGH                   NEIGHBORHOOD
##                             0                              0
##        BUILDING.CLASS.CATEGORY           TAX.CLASS.AT.PRESENT
##                             0                            738
##                         BLOCK                            LOT
##                             0                              0
##      BUILDING.CLASS.AT.PRESENT                        ADDRESS
##                           738                              0
##              APARTMENT.NUMBER                       ZIP.CODE
##                         65496                              0
##             RESIDENTIAL.UNITS                COMMERCIAL.UNITS
##                             0                              0
##                   TOTAL.UNITS                LAND.SQUARE.FEET
##                             0                              0
##             GROSS.SQUARE.FEET                      YEAR.BUILT
##                             0                              0
##      TAX.CLASS.AT.TIME.OF.SALE BUILDING.CLASS.AT.TIME.OF.SALE
##                             0                              0
##                    SALE.PRICE                       SALE.DATE
##                             0                              0
```

Vidimo da se javlja kod kolona TAX.CLASS.AT.PRESENT, BUILDING.CLASS.AT.PRESENT i APARTMENT.NUMBER. Kod TAX.CLASS.AT.PRESENT i BUILDING.CLASS.AT.PRESENT se javlja 738 puta tako da je vrlo verovatno da se radi o istim redovima što ćemo i proveriti.

Proveru smo odradili korišćenjem logičkog operatora & i dobili da se nedostajuće vrednosti nalaze u istim redovima.

```r
isti_redovi <- (data$TAX.CLASS.AT.PRESENT == " ") & (data$BUILDING.CLASS.AT.P
RESENT == " ")
sum(isti_redovi)

## [1] 738
```

Pošto se radi o istih 738 redova možemo da zaključimo da se radi o sistemskom razlogu zbog kog nedostaju podaci a ne o nasumičnom nedostajanju.

Za početak ćemo proveriti da li su missing vrednosti koncentrisane u jednoj opštini ili naselju (BOROUGH i NEIGHBORHOOD).

```r
data_fali <- data[isti_redovi, ]
table(data_fali$BOROUGH)

##
##   1   3   4   5
## 275 352 110   1

sort(table(data_fali$NEIGHBORHOOD), decreasing = TRUE)

##
##           SHEEPSHEAD BAY                  CHELSEA       WILLIAMSBURG-NORTH
##                      133                       65                       56
##           HARLEM-CENTRAL               GREENPOINT           FLUSHING-NORTH
##                       50                       40                       39
##                 FLATIRON              MURRAY HILL                  ASTORIA
##                       35                       29                       26
##       BEDFORD STUYVESANT  UPPER EAST SIDE (79-96)             FOREST HILLS
##                       26                       24                       23
##         LONG ISLAND CITY             MIDTOWN WEST    DOWNTOWN-FULTON FERRY
##                       19                       15                       14
##                  MADISON              BENSONHURST             BOROUGH PARK
##                       14                       13                       11
##                  CLINTON            CROWN HEIGHTS                  MIDWOOD
##                       10                       10                        9
## UPPER WEST SIDE (96-116)              MIDTOWN CBD                     SOHO
##                        9                        8                        7
##                 BUSHWICK             CIVIC CENTER  UPPER EAST SIDE (59-79)
##                        6                        6                        6
##                  TRIBECA               PARK SLOPE        WILLIAMSBURG-EAST
##                        5                        4                        4
##             CLINTON HILL             SPRING CREEK              SUNSET PARK
##                        3                        3                        3
##            ALPHABET CITY                   CORONA                FINANCIAL
##                        2                        2                        2
##  UPPER WEST SIDE (59-79)                 ARROCHAR              BOERUM HILL
##                        2                        1                        1
##         BROOKLYN HEIGHTS      OCEAN PARKWAY-NORTH      SPRINGFIELD GARDENS
##                        1                        1                        1
```

Na osnovu raspodele po BOROUGH obeležju primećujemo da se većina redova sa nedostajućim “AT PRESENT” klasifikacijama nalazi u Brooklynu (352) i Manhattanu (275).

Dok po NEIGHBORHOOD obeležju uočavamo veću koncentraciju u Sheepshead Bay (133), Chelsea (65) i Williamsburg-North (56), što nam ukazuje da nedostajanje nije u potpunosti slučajno.

Nastavljamo ispitivanje povezanosti nedostajućih vrednosti za obeležja TAX.CLASS.AT.PRESENT i BUILDING.CLASS.AT.PRESENT sa ostalim obeležjima, ali ćemo uzeti u obzir potencijalnu povezanost sa obeležjima BOROUGH i NEIGHBORHOOD.

Sledeće obeležje koje potencijalno utiče na nedostajanje ovih vrednosti je obeležje za kategoriju klase objekta (BUILDING.CLASS.CATEGORY) što i proveravamo.

```r
head(sort(table(data_fali$BUILDING.CLASS.CATEGORY), decreasing = TRUE), 15)
```

```
##
##  13 CONDOS - ELEVATOR APARTMENTS
##                                          506
##  44 CONDO PARKING
##                                           95
##  15 CONDOS - 2-10 UNIT RESIDENTIAL
##                                           58
##  04 TAX CLASS 1 CONDOS
##                                           26
##  47 CONDO NON-BUSINESS STORAGE
##                                           26
##  43 CONDO OFFICE BUILDINGS
##                                            9
##  10 COOPS - ELEVATOR APARTMENTS
##                                            3
##  31 COMMERCIAL VACANT LAND
##                                            3
##  03 THREE FAMILY DWELLINGS
##                                            2
##  16 CONDOS - 2-10 UNIT WITH COMMERCIAL UNIT
##                                            2
##  46 CONDO STORE BUILDINGS
##                                            2
##  01 ONE FAMILY DWELLINGS
##                                            1
##  05 TAX CLASS 1 VACANT LAND
##                                            1
## 11A CONDO-RENTALS
##                                            1
##  36 OUTDOOR RECREATIONAL FACILITIES
##                                            1
```

Primećujemo da se nedostajuće vrednosti u kolonama TAX.CLASS.AT.PRESENT i BUILDING.CLASS.AT.PRESENT skoro uvek pojavljuju kod condo kategorija. Condo nekretnine se vode kao zasebne jedinice (stanovi i prateće jedinice poput parkinga), pa “AT PRESENT” klasifikacija nije uvek dostupna, dok su podaci “AT TIME OF SALE“ popunjeni jer se odnose na stanje u trenutku prodaje.

Prethodnim pronalaženjem u kojim kolonama postoje nedostajuće vrednosti u vidu praznog stringa zaključujemo da svaki red u kom nedostaju vrednosti za obeležja TAX.CLASS.AT.PRESENT i BUILDING.CLASS.AT.PRESENT ima popunjene vrednosti za odgovarajuća obeležja u trenutku prodaje (TAX.CLASS.AT.TIME.OF.SALE i BUILDING.CLASS.AT.TIME.OF.SALE).

Ova činjenica, kao i provera povezanosti sa drugim obeležjima (BOROUGH, NEIGHBORHOOD i BUILDING.CLASS.CATEGORY) nam ukazuje da ove vrednosti ne nedostaju nasumično, ali zato što je cilj našeg projekta predikcija SALE.PRICE obeležja u trenutku prodaje zbog relevantnosti ćemo se opredeliti za AT.TIME.OF.SALE obeležja, a AT.PRESENT obeležja ćemo posmatrati kao sekundaran podatak.

```
sum(data$APARTMENT.NUMBER == " ")

## [1] 65496
```

Pored dve prethodno pomenute kolone najveći broj praznih polja se javio za obeležje APARTMENT.NUMBER. Veliki broj nedostajućih vrednosti za ovo obležje se može objasniti time što kuće nemaju broj apartmana, tako da je potrebno da proverimo koliko podataka nedostaje za broj apartmana po klasama nekretnina.

```
head(sort(table(data$BUILDING.CLASS.CATEGORY[data$APARTMENT.NUMBER == " "]),d
ecreasing = TRUE), 15)

##
## 01 ONE FAMILY DWELLINGS
##                                        18222
## 02 TWO FAMILY DWELLINGS
##                                        15809
## 10 COOPS - ELEVATOR APARTMENTS
##                                        12900
## 03 THREE FAMILY DWELLINGS
##                                         4347
## 07 RENTALS - WALKUP APARTMENTS
##                                         3058
## 09 COOPS - WALKUP APARTMENTS
```

```
##                                          2766
## 05 TAX CLASS 1 VACANT LAND
##                                          1247
## 17 CONDO COOPS
##                                          1197
## 22 STORE BUILDINGS
##                                           934
## 13 CONDOS - ELEVATOR APARTMENTS
##                                           661
## 14 RENTALS - 4-10 UNIT
##                                           604
## 29 COMMERCIAL GARAGES
##                                           587
## 31 COMMERCIAL VACANT LAND
##                                           458
## 04 TAX CLASS 1 CONDOS
##                                           412
## 21 OFFICE BUILDINGS
##                                           350
```

Kao što je i očekivano, veliki broj nekretnina bez upisanog broja apartmana odnosi se na porodične kuće, kod kojih broj stana nije bitan.Primećujemo da postoji i približno 20.000 zapisa koji pripadaju kategoriji apartmana, a nemaju evidentiran broj jedinice. Ovakva situacija može biti posledica prodaje celokupne zgrade ili nepotpunog unosa podataka u dataset.

Obeležje APARTMENT.NUMBER nema direktan uticaj na formiranje cene nekretnine, jer predstavlja isključivo identifikacionu oznaku jedinice. Jedini indirektni uticaj mogao bi se odnositi na broj sprata (stanovi na višim spratovima obično imaju veću cenu), ali dataset ne sadrži informaciju o spratu, niti o njoj možemo pouzdano zaključiti na osnovu samog broja apartmana. Upravo iz ovog razloga i nerelevantnosti za sve tipove nekretnina ovo obeležje ćemo izostaviti iz modela.

Kolone APARTMENT.NUMBER, TAX.CLASS.AT.PRESENT i BUILDING.CLASS.AT.PRESENT uklanjamo iz skupa podataka jer ne doprinose predikciji za SALE.PRICE, dok su relevantne vrednosti već dostupne kroz TAX.CLASS.AT.TIME.OF.SALE i BUILDING.CLASS.AT.TIME.OF.SALE.

```
data <- data %>%
  select(-TAX.CLASS.AT.PRESENT, -BUILDING.CLASS.AT.PRESENT, -APARTMENT.NUMBER
)
```

Pošto smo završili sa obradom nedostajućih vrednosti u vidu praznog niza karaktera, nastavljamo sa traženjem preostalih nedostajućih vrednosti drugog formata. Prethodnim

prikazom podataka iz dataset-a uočavamo da u našim podacima postoje nedostajuće vrednosti u vidu “-” za naše ciljno obeležje SALE.PRICE.

```
head(data$SALE.PRICE, 10)
```

```
##  [1] "6625000"  " -  "     " -  "     "3936272"  "8000000"  " -  "
##  [7] "3192840"  " -  "     " -  "     "16232000"
```

Iz predostrožnosti proveravamo da li se ovaj tip nedostajuće vrednosti javlja u još nekoj koloni našeg skupa podataka pomoću funkcije colSums.

```
colSums(data == "-")
```

```
##                        BOROUGH                   NEIGHBORHOOD
##                              0                              0
##        BUILDING.CLASS.CATEGORY                          BLOCK
##                              0                              0
##                            LOT                        ADDRESS
##                              0                              0
##                       ZIP.CODE              RESIDENTIAL.UNITS
##                              0                              0
##               COMMERCIAL.UNITS                    TOTAL.UNITS
##                              0                              0
##               LAND.SQUARE.FEET              GROSS.SQUARE.FEET
##                              0                              0
##                     YEAR.BUILT      TAX.CLASS.AT.TIME.OF.SALE
##                              0                              0
## BUILDING.CLASS.AT.TIME.OF.SALE                     SALE.PRICE
##                              0                              0
##                      SALE.DATE
##                              0
```

Možemo da primetimo da na ovaj način ne možemo da “uhvatimo” ove nedostajuće vrednosti, jer u izlazu funkcije colSums možemo da primetimo da nam je broj ovakvih redova za obeležje SALE.PRICE jednak 0 iako u realnosti to nije slučaj.

Ovo nas navodi na pretpostavku da se ne radi samo o jednom karakteru (samo “-”), već da je reč o crtici okruženoj sa blanko karakterima (“ - ” , “ - ”, itd.). Pristupićemo detektovanju ovih vrednosti tako što ćemo iskoristiti jednu takvu vrednost iz kolone SALE.PRICE i pomoću nje i colSums funkcije pronaći ostale.

```
crtica=data$SALE.PRICE[2]
colSums(data == crtica)
```

```
##                        BOROUGH                   NEIGHBORHOOD
##                              0                              0
##        BUILDING.CLASS.CATEGORY                          BLOCK
##                              0                              0
##                            LOT                        ADDRESS
```

```
##                                0                                0
##                         ZIP.CODE                RESIDENTIAL.UNITS
##                                0                                0
##                 COMMERCIAL.UNITS                      TOTAL.UNITS
##                                0                                0
##                 LAND.SQUARE.FEET                GROSS.SQUARE.FEET
##                            26252                            27612
##                       YEAR.BUILT        TAX.CLASS.AT.TIME.OF.SALE
##                                0                                0
## BUILDING.CLASS.AT.TIME.OF.SALE                       SALE.PRICE
##                                0                            14561
##                        SALE.DATE
##                                0
```

Kao što smo pretpostavili SALE.PRICE nije jedino obeležje sa ovakvim nedostajućim vrednostima, već one nedostaju i u kolonama LAND.SQUARE.FEET i GROSS.SQUARE.FEET. Sada je potrebno da pristupimo hendlovanju ovih vrednosti da bismo ih kasnije pretvorili u numeričke jer su trenutno char tipa upravo zbog pojavljivanja "-".

```r
str(data[, c("LAND.SQUARE.FEET", "GROSS.SQUARE.FEET", "SALE.PRICE")])
```

```
## 'data.frame':    84548 obs. of  3 variables:
##  $ LAND.SQUARE.FEET : chr  "1633" "4616" "2212" "2272" ...
##  $ GROSS.SQUARE.FEET: chr  "6440" "18690" "7803" "6794" ...
##  $ SALE.PRICE       : chr  "6625000" " -  " " -  " "3936272" ...
```

U poljima kolone SALE.PRICE osim znaka "-" često se pojavljuje i vrednost 0 gde one predstavljaju transakcije koje nisu ostvarene klasičnom prodajom (poklon, nasleđivanje, ili nepopunjeni podaci; napomenuto u opisu dataseta na Kaggle platformi) i zato ne daju korisnu informaciju za predikciju cena.

Ukoliko bismo se opredelili za imputaciju vrednosti doslo bi do sigurne pristrasnosti (bias-a), zbog toga bi trebalo ukloniti te redove. Polja sa "-" ćemo zameniti sa NA vrednostima u ovom obeležju. Ponovnim korišćenjem colSums funkcije uz obavezno dodavanje atributa na.rm = TRUE radi ignorisanja NA vrednosti jer bi nam u suprotnom za ukupan broj pojavljivanja bilo prikazano NA. Primećujemo da smo uspešno izmenili ove vrednosti.

```r
data$SALE.PRICE[data$SALE.PRICE == crtica] <- NA
colSums(data == crtica, na.rm = TRUE)
```

```
##                        BOROUGH                    NEIGHBORHOOD
##                              0                               0
##         BUILDING.CLASS.CATEGORY                           BLOCK
##                              0                               0
##                            LOT                         ADDRESS
##                              0                               0
```

```
##                       ZIP.CODE              RESIDENTIAL.UNITS
##                              0                              0
##               COMMERCIAL.UNITS                    TOTAL.UNITS
##                              0                              0
##               LAND.SQUARE.FEET              GROSS.SQUARE.FEET
##                          26252                          27612
##                     YEAR.BUILT      TAX.CLASS.AT.TIME.OF.SALE
##                              0                              0
## BUILDING.CLASS.AT.TIME.OF.SALE                     SALE.PRICE
##                              0                              0
##                      SALE.DATE
##                              0
```

Za obeležja LAND.SQUARE.FEET i GROSS.SQUARE.FEET za početak imamo isti pristup kao i za SALE.PRICE, zamena svih "-" sa NA vrednošću. Ponovnim pozivom colSums uočavamo da smo uspešno izvršili zamenu.

```
data$LAND.SQUARE.FEET[data$LAND.SQUARE.FEET == crtica] <- NA
data$GROSS.SQUARE.FEET[data$GROSS.SQUARE.FEET == crtica] <- NA

colSums(data == crtica, na.rm = TRUE)
```

```
##                       BOROUGH                   NEIGHBORHOOD
##                              0                              0
##        BUILDING.CLASS.CATEGORY                          BLOCK
##                              0                              0
##                           LOT                        ADDRESS
##                              0                              0
##                       ZIP.CODE              RESIDENTIAL.UNITS
##                              0                              0
##               COMMERCIAL.UNITS                    TOTAL.UNITS
##                              0                              0
##               LAND.SQUARE.FEET              GROSS.SQUARE.FEET
##                              0                              0
##                     YEAR.BUILT      TAX.CLASS.AT.TIME.OF.SALE
##                              0                              0
## BUILDING.CLASS.AT.TIME.OF.SALE                     SALE.PRICE
##                              0                              0
##                      SALE.DATE
##                              0
```

Pošto želimo da za ove NA vrednosti u kolonama LAND.SQUARE.FEET i GROSS.SQUARE.FEET izvršimo odgovarajuću imputaciju vrednosti neophodno je da ove kolone pretvorimo u numerički tip, koristeći funkciju as.numeric.

```
data$SALE.PRICE <- as.numeric(data$SALE.PRICE)
data$LAND.SQUARE.FEET <- as.numeric(data$LAND.SQUARE.FEET)
data$GROSS.SQUARE.FEET <- as.numeric(data$GROSS.SQUARE.FEET)
str(data[, c("LAND.SQUARE.FEET", "GROSS.SQUARE.FEET", "SALE.PRICE")])
```

```
## 'data.frame':    84548 obs. of  3 variables:
##  $ LAND.SQUARE.FEET : num  1633 4616 2212 2272 2369 ...
##  $ GROSS.SQUARE.FEET: num  6440 18690 7803 6794 4615 ...
##  $ SALE.PRICE       : num  6625000 NA NA 3936272 8000000 ...
```

Pošto smo proverili sve tipove nedostajućih vrednosti kolonu ADDRESS isto uklanjamo jer sadrži veoma veliki broj jedinstvenih vrednosti i ponaša se kao identifikator, pa model može da nauči specifične adrese iz trening skupa umesto opštih obrazaca, što dovodi do overfitting-a i slabije generalizacije na nove nekretnine. Jedini slučaj gde bi nam ADDRESS obeležje bilo korisno jeste kod popunjavanja nedostajućih vrednosti u kolonama BOROUGH, NEIGHBORHOOD i ZIP.CODE, ali pošto se u ovim kolonama takve vrednosti ne javljaju i pošto ove kolone sadrže informacije o lokaciji ADDRESS obeležje nam nije potrebno.

```
data$ADDRESS <- NULL
```

Sada proveravamo procentualni udeo podataka sa NA vrednošću u koloni SALE.PRICE gde brojNA_SP označava upravo broj takvih redova.

```
brojNA_SP <- sum(is.na(data$SALE.PRICE))
(brojNA_SP / nrow(data)) * 100

## [1] 17.22217
```

Iako redova sa NA vrednošću u SALE.PRICE ima oko 17%, mi ćemo ih ukloniti zato što je SALE.PRICE ciljna promenljiva i bez poznate prodajne cene ne možemo da treniramo regresioni model, a ni da ga pouzdano ocenimo. Sama imputacija vrednosti u ciljnu promenljivu dovela bi do biasa.

```
data <- data[!is.na(data$SALE.PRICE), ]
sum(is.na(data$SALE.PRICE))

## [1] 0
```

Pozivanjem sum funkcije primećujemo da smo ove redove uspešno uklonili iz data seta.

Konverzija tipova podataka

Pre početka modeliranja podataka neophodno je izvršiti pravilnu konverziju tipova kolona. Prilikom učitavanja skupa podataka, kod našeg data seta su pri ucitavnju sve kolone bile postavljene na tip karakter. Neodgovarajući tip promenljive može dovesti do pogrešne interpretacije podataka, loše statističke analize i loših rezultata modela. Iz tog razloga, svaka promenljiva se transformiše u odgovarajući tip (factor, ordered factor, numeric ili Date) u skladu sa njenim značenjem.

```
data$NEIGHBORHOOD <- as.factor(data$NEIGHBORHOOD)
data$BUILDING.CLASS.CATEGORY <- as.factor(data$BUILDING.CLASS.CATEGORY)
```

```r
data$BUILDING.CLASS.AT.TIME.OF.SALE <- as.factor(data$BUILDING.CLASS.AT.TIME.
OF.SALE)
data$BOROUGH <- as.factor(data$BOROUGH)
data$ZIP.CODE <- as.factor(data$ZIP.CODE)

data$TAX.CLASS.AT.TIME.OF.SALE <- factor(
  as.character(data$TAX.CLASS.AT.TIME.OF.SALE),
  levels = c("1", "2", "3", "4"),
  ordered = TRUE
)

data$SALE.DATE <- as.Date(data$SALE.DATE)


data$RESIDENTIAL.UNITS <- as.numeric(data$RESIDENTIAL.UNITS)
data$COMMERCIAL.UNITS  <- as.numeric(data$COMMERCIAL.UNITS)
data$TOTAL.UNITS       <- as.numeric(data$TOTAL.UNITS)
data$YEAR.BUILT        <- as.numeric(data$YEAR.BUILT)
```

FACTOR KOLONE

NEIGHBORHOOD

Ova kolona predstavlja naziv naselja, odnosno kategorijsku promenljivu bez poretka.

BUILDING.CLASS.CATEGORY

Ova promenljiva označava tip objekta (condo, rentals)i nema numerički smisao ni poredak.

BUILDING.CLASS.AT.TIME.OF.SALE

Predstavlja šifru klase objekta u trenutku prodaje. Pošto su to oznake (C2, R1), tretiraju se kao nominalne kategorije bez poretka.

BOROUGH

Označava opštinu (1–5), ali ti brojevi ne predstavljaju kvantitativnu veličinu već kategorije. Pretvaranjem u factor sprečavamo model da pogrešno zaključi da je 5 važnije od 1 na primer.

ZIP.CODE

Ova kolona označava poštanski broj po delovima grada i pre ove promene je bila int što nije dobro jer naš model može da pomisli da je na primer postanski broj 11001 bolji od 10001 jer je veći i ako to nije slučaj.

TAX.CLASS.AT.TIME.OF.SALE

Ova promenljiva ima poredak (1 < 2 < 3 < 4), pa je menjamo u ordered factor.

DATE KOLONA

SALE.DATE

Ova kolona predstavlja datum prodaje objekta tako da nju pretvaramo u datum.

NUMERIC KOLONE

RESIDENTIAL.UNITS

Predstavlja broj stambenih jedinica u objektu. Pošto je to kvantitativna veličina, mora biti numeričkog tipa.

COMMERCIAL.UNITS

Broj poslovnih jedinica u objektu. Kao i prethodna kolona, predstavlja numeričku veličinu.

TOTAL.UNITS

Ukupan broj jedinica u objektu.

YEAR.BUILT

Pretvaranjem ove kolone u numeric će nam kasnije omogućiti da lakse izračunamo starost objekta.

Analiza target kolone

Ciljna promenljiva SALE.PRICE označava prodajnu cenu nekretnine u američkim dolarima. Razumevanje njene distribucije je ključno za pravilno modelovanje

```
summary(data$SALE.PRICE)

##      Min.   1st Qu.    Median      Mean   3rd Qu.      Max.
## 0.000e+00 2.300e+05 5.350e+05 1.282e+06 9.500e+05 2.210e+09
```

Primetno je da je srednja vrednost znatno veća od medijane, što ukazuje na prisustvo par izuzetno skupih nekretnina koje povlače prosečnu cenu nagore. Većina nekretnina se nalazi u nižem i srednjem cenovnom opsegu, dok mali broj objekata dostiže ekstremno visoke vrednosti.

```r
ggplot(data, aes(x = SALE.PRICE)) +
  geom_histogram(binwidth = 50000,
                 fill = "blue",
                 color = "black",
                 alpha = 0.7) +
  scale_x_continuous(labels = comma, limits = c(0, 5000000)) +
  coord_cartesian(ylim = c(0, 4000)) +
  labs(
    title = "Distribucija prodajne cene",
    x = "Prodajna cena",
    y = "Broj nekretnina"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

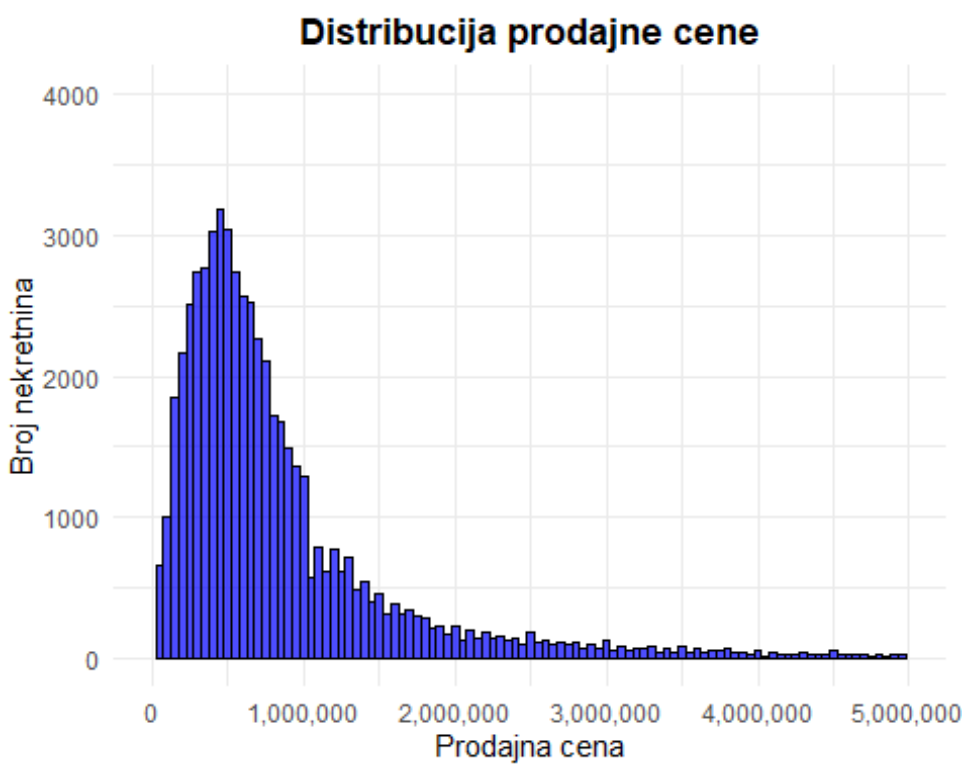

Linearni regresioni modeli funkcionišu najbolje kada reziduali slede približno normalnu raspodelu. Ako je ciljana promenljiva veoma asimetrična, model može biti podložan greškama izazvanim ekstremno visokim ili niskim vrednostima, jer pokušava da se prilagodi tim outlierima. Da bismo približili distribuciju ciljne promenljive normalnoj, uklonićemo ekstremne vrednosti (outliere).

Dalje, da bi smo izvršili pouzdanu imputaciju odgovarajućih vrednosti u kolone LAND.SQUARE.FEET, GROSS.SQUARE.FEET i YEAR.BUILT potrebno je da prethodno detektujemo i analiziramo outliere koji bi potencijalno uticali na statistike za popunjavanje.

Univarijantna analiza i analiza outliera

Pre identifikacije i uklanjanja outliera, prvo ćemo ukloniti duple redove kako bismo obezbedili tačnost i konzistentnost podataka. Broj redova pre brisanja duplikata je 84548 što možemo videti pomoću funkcije nrow.

```
nrow(data)

## [1] 69987
```

Postojanje duplih redova smo prvo proverili funkcijom sum(duplicated(data)), kojom se identifikuju potpuno identični redovi u data setu, odnosno zapisi kod kojih su sve kolone iste. Ovim korakom proveravaju se tehnički duplikati nastali greškom prilikom unosa ili spajanja podataka. Time se obezbeđuje da svaki red predstavlja jedinstven zapis. Ovakvih duplikata ima 469.

```
sum(duplicated(data))

## [1] 469
```

Pored toga, izvršena je i dodatna provera putem ključa. Ključ predstavlja kombinaciju kolona koje zajedno jedinstveno identifikuju jednu kupovinu. U ovom slučaju formirali smo složeni ključ korišćenjem obeležja BOROUGH, BLOCK, LOT, SALE.DATE i SALE.PRICE, jer njihova kombinacija logički opisuje jednu prodaju. Kreiranjem ovog ključa i primenom funkcije sum(duplicated(key)) proverili smo da li postoje zapisi koji možda nisu potpuno identični u svim kolonama, ali se odnose na istu kupovinu. Na taj način obuhvaćeni su i tehnički i logički duplikati. Možemo videti da njih ima 519.

```
key <- with(data, paste(BOROUGH, BLOCK, LOT, SALE.DATE, SALE.PRICE, sep = "_"
))
sum(duplicated(key))

## [1] 519
```

Nakon što smo utvrdili postojanje duplikata, sada ih trebamo obrisati tako da zadržimo samo jedinstvene zapise na osnovu definisanog ključa.

```
data <- distinct(data, BOROUGH, BLOCK, LOT, SALE.DATE, SALE.PRICE, .keep_all
= TRUE)
```

Pošto je broj redova pre brisanja duplikata bio 69987, a trebalo je da obrišemo 519, očekujemo da će broj redova u očišćenom data setu biti 69468 (69987- 519), a to možemo i da proverimo ponovnim korišćenjem funkcije nrow.

```
nrow(data)

## [1] 69468
```

Sada smo sigurni da smo obrisali sve tehničke i logičke duplikate.

Dalje uklanjamo nelogicne vrednosti iz naseg data seta. Prvo uklanjamo vrednosti manje od 0 za obeležje SALE.PRICE.

```
data <- data %>%
  filter(!is.na(SALE.PRICE), SALE.PRICE > 0)
```

Slično sada to radimo i za obeležja LAND.SQUARE.FEET i GROSS.SQUARE.FEET pri čemu ostavljamo NA vrednosti za koje ćemo kasnije izvršiti imputaciju.

```
data <- data %>%
  filter(is.na(GROSS.SQUARE.FEET) | GROSS.SQUARE.FEET > 0) %>%
  filter(is.na(LAND.SQUARE.FEET)  | LAND.SQUARE.FEET  > 0)
```

Obeležja TOTAL.UNITS, RESIDENTIAL.UNITS i COMMERCIAL.UNITS ne smeju biti negativna (ukoliko nisu NA).

```
data <- data %>%
  filter(is.na(TOTAL.UNITS)        | TOTAL.UNITS        >= 0) %>%
  filter(is.na(RESIDENTIAL.UNITS)  | RESIDENTIAL.UNITS  >= 0) %>%
  filter(is.na(COMMERCIAL.UNITS)   | COMMERCIAL.UNITS   >= 0)
```

Univarijantna analiza podataka

YEAR.BUILT

Na boxplotu obeležja YEAR.BUILT primećujemo da je većina vrednosti skoncentrisana u realnom opsegu (od oko 1900–2000+), dok postoji nekoliko ekstremnih vrednosti (0, 1000, itd.) koje su daleko od vecine podataka.

```
ggplot(data, aes(y = YEAR.BUILT)) +
  geom_boxplot(outlier_alpha = 0.5) +
  labs(
    title = "Boxplot za YEAR.BUILT",
    y = "YEAR.BUILT",
    x = ""
  ) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

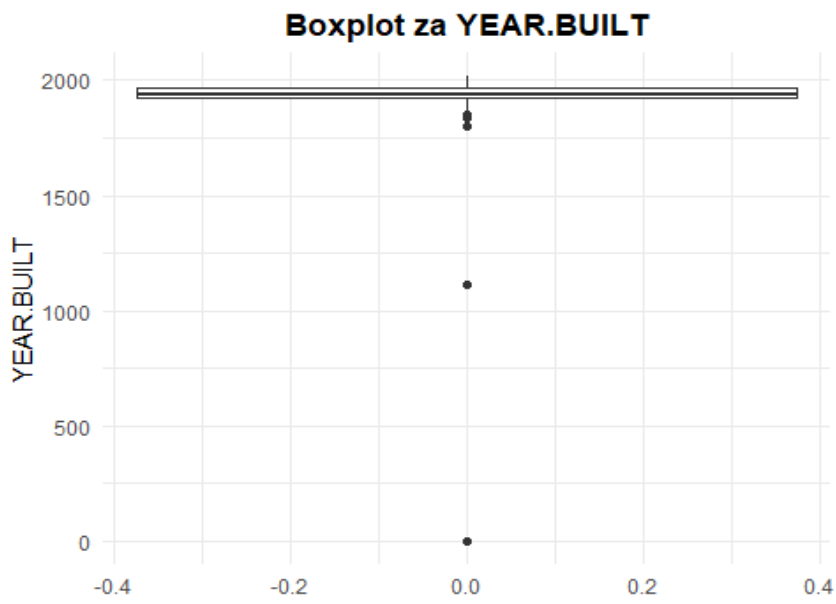

Takve vrednosti su nerealne za godinu izgradnje i njih ćemo ukloniti.

```
trenutna_godina <- as.integer(format(Sys.Date(), "%Y"))

data <- data %>%
  filter(is.na(YEAR.BUILT) | (YEAR.BUILT >= 1800 & YEAR.BUILT <= trenutna_god
ina))
```

TOTAL.UNITS

Raspodela promenljive TOTAL.UNITS je izrazito desno-asimetrična (right-skewed). Primećujemo da najveći broj nekretnina ima mali broj jedinica (0–2), dok se manji broj njih javlja sa većim vrednostima, što formira dugačak desni rep. Pošto je TOTAL.UNITS obeležje izvedeno iz RESIDENTIAL.UNITS i COMMERCIAL.UNITS, njega ne uključujemo zajedno sa njima u model kako bismo izbegli multikolinearnost.

```
ggplot(data, aes(x = TOTAL.UNITS)) +
  geom_histogram(binwidth = 1, boundary = 0, color = "black", alpha = 0.7) +
  coord_cartesian(xlim = c(0, 20)) +
  labs(title = "Raspodela TOTAL.UNITS") +
  theme_minimal()
```

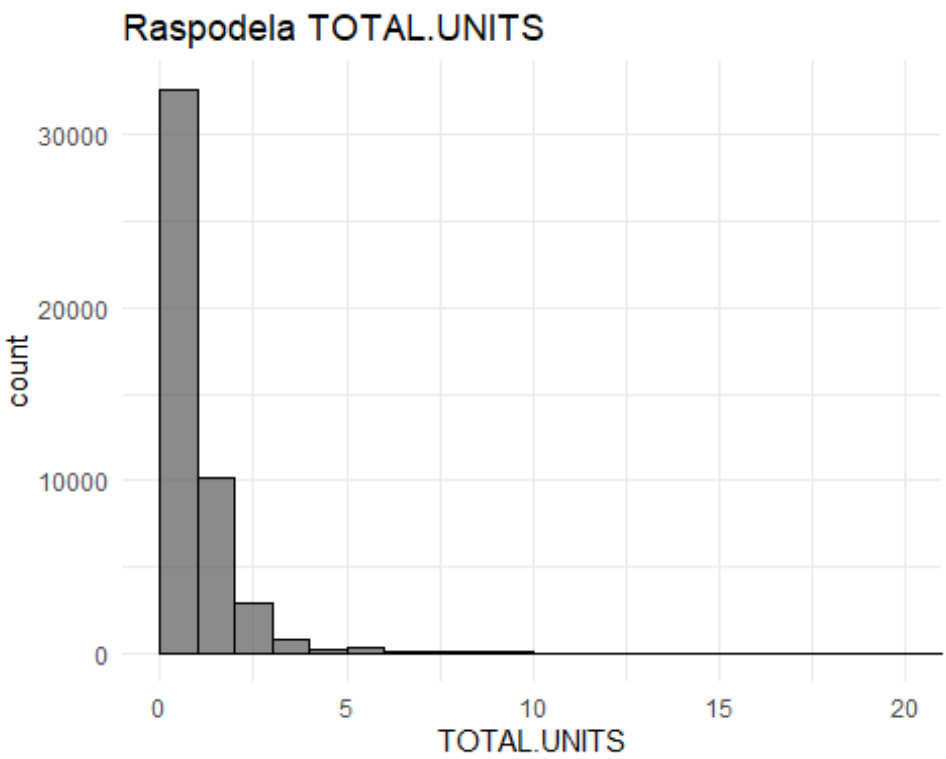

RESIDENTIAL.UNITS

Obeležje RESIDENTIAL.UNITS je koncentrisano na malim vrednostima uz retku pojavu većeg broja stambenih jedinica. Nećemo koristiti logaritam za ovu raspodelu jer je RESIDENTIAL.UNITS kolona sa uglavnom malim celobrojnim vrednostima ,pa logaritam ne menja mnogo između tih malih vrednosti. Zbog ovakve raspodele i lakše interpretacije u modelu, koristićemo grupisanje u kategorije (0, 1, 2–3, 4+) čime ćemo se baviti u poglavlju Feature engineering.

```
ggplot(data, aes(x = RESIDENTIAL.UNITS)) +
  geom_histogram(binwidth = 1, boundary = 0, color = "black", alpha = 0.7) +
  coord_cartesian(xlim = c(0, 15)) +
  labs(title = "Raspodela RESIDENTIAL.UNITS") +
  theme_minimal()
```

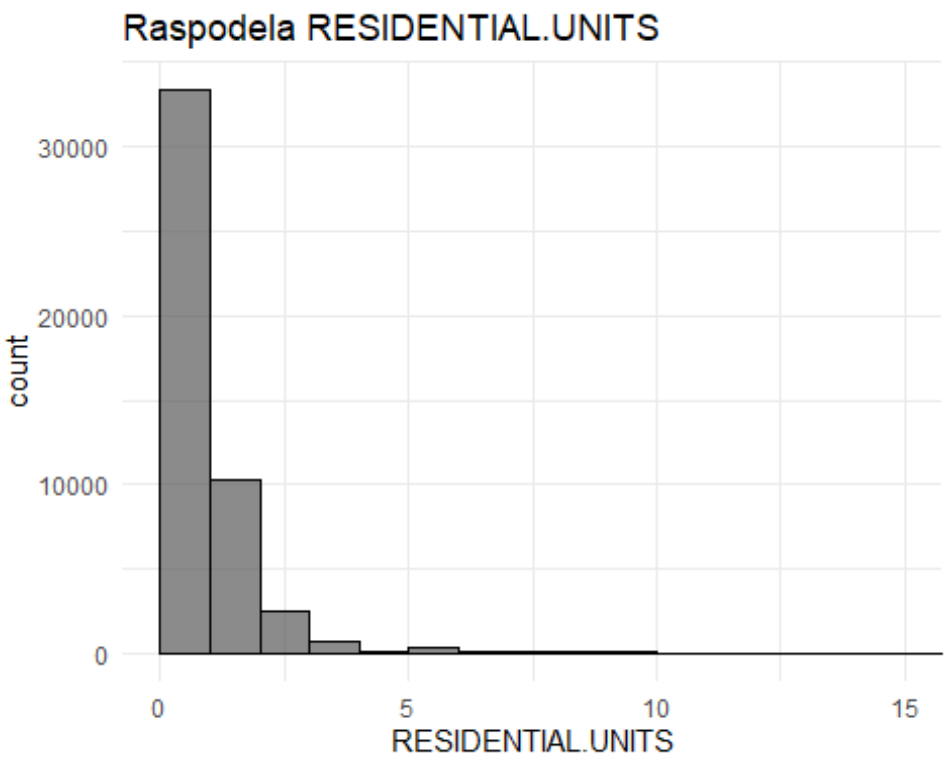

COMMERCIAL.UNITS

Za COMMERCIAL.UNITS primećujemo da je većina vrednosti 0, dok su slučajevi sa više od 1 komercijalne jedinice retki. Zato ćemo ovu promenljivu u modelu predstaviti preko binarnog indikatora (da li objekat ima bar jednu komercijalnu jedinicu, detaljnije u Feature engineering poglavlju), što daje stabilnije i interpretabilnije obeležje.

```
ggplot(data, aes(x = COMMERCIAL.UNITS)) +
  geom_histogram(binwidth = 1, boundary = 0, color = "black", alpha = 0.7) +
  coord_cartesian(xlim = c(0, 10)) +
  labs(title = "Raspodela COMMERCIAL.UNITS") +
  theme_minimal()
```

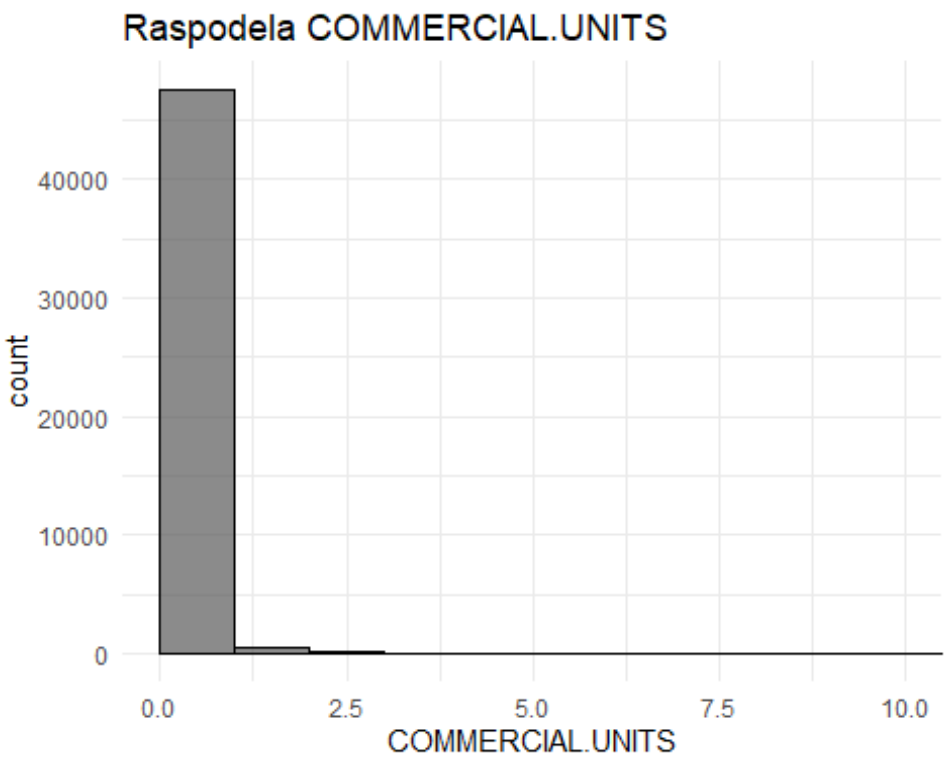

LAND.SQUARE.FEET

Raspodela je jako desno-asimetrična i ima ekstremne vrednosti, pa linearna osa daje neinformativan prikaz. Zbog toga se opredeljujemo za logaritmovanu skalu.

```
ggplot(data, aes(x = LAND.SQUARE.FEET)) +
  geom_histogram(bins = 60, color = "black", alpha = 0.7) +
  scale_x_log10() +
  labs(title = "LAND.SQUARE.FEET",
       x = "LAND.SQUARE.FEET (log10 skala)", y = "Broj") +
  theme_minimal()
```

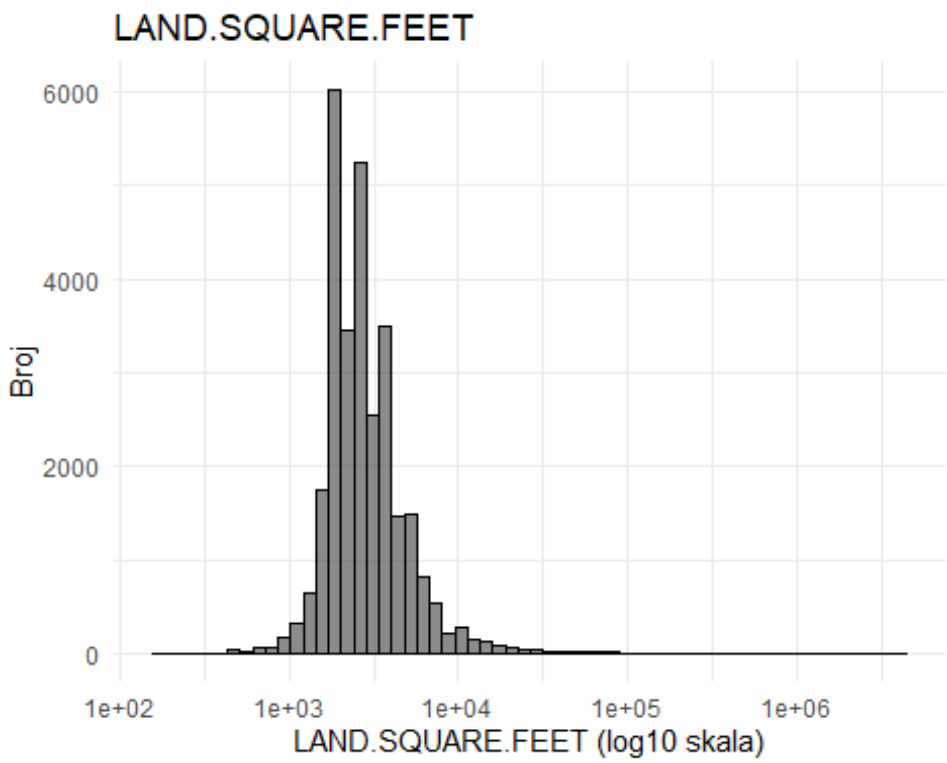

GROSS.SQUARE.FEET

Pošto bruto površina ima veliki raspon i ekstremne vrednosti, logaritamska skala na osi omogućava čitljiviji prikaz raspodele.

```
ggplot(data, aes(x = GROSS.SQUARE.FEET)) +
  geom_histogram(bins = 60, color = "black", alpha = 0.7) +
  scale_x_log10() +
  labs(title = "GROSS.SQUARE.FEET",
       x = "GROSS.SQUARE.FEET (log10 skala)", y = "Broj") +
  theme_minimal()
```

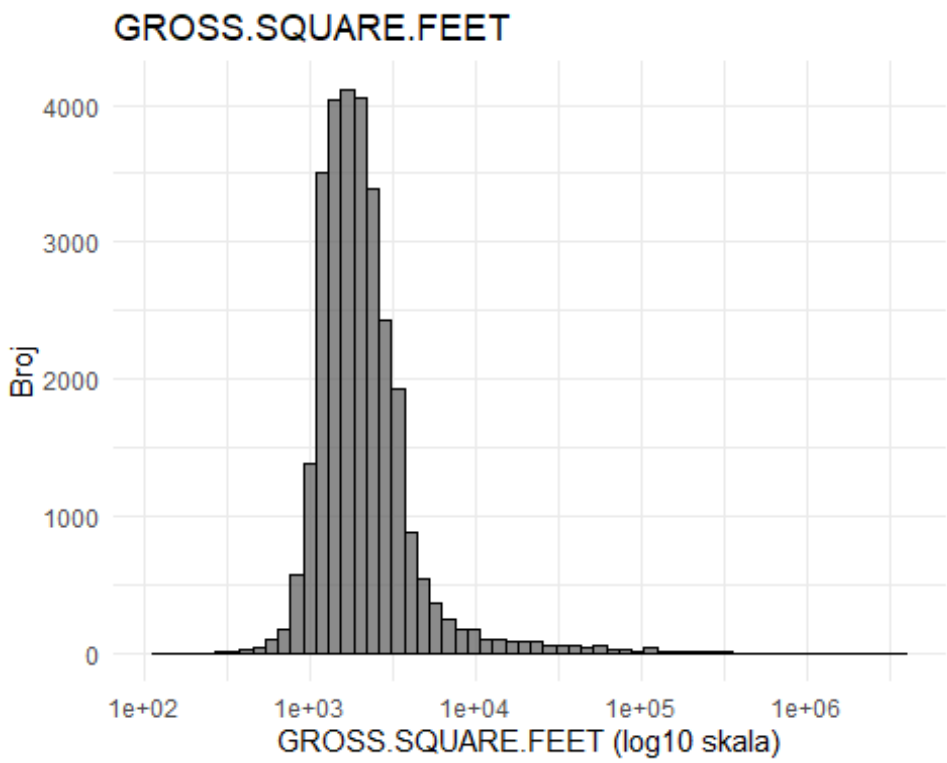

Kako smo analizirali raspodelu cena nekretnina (SALE.PRICE), primetili smo da je originalna distribucija jako nagnuta udesno zbog nekoliko ekstremno visokih vrednosti. Da bismo dobili pregledniju i simetričniju raspodelu, primenili smo logaritamsku transformaciju baze 10, kreirajući novu kolonu log_sale_price. Slično je urađeno i za LAND.SQUARE.FEET i GROSS.SQUARE.FEET.

```
data <- data %>%
  mutate(
    log_sale_price = log10(SALE.PRICE),
    log_gross_sqft = ifelse(is.na(GROSS.SQUARE.FEET), NA, log10(GROSS.SQUARE.
FEET + 1)),
    log_land_sqft  = ifelse(is.na(LAND.SQUARE.FEET),  NA, log10(LAND.SQUARE.F
EET + 1)))
```

Grafik jasno prikazuje da je distribucija log_sale_price bliža normalnoj raspodeli, sa smanjenim uticajem outliera, što olakšava vizuelnu interpretaciju i statističke analize.

```
ggplot(data %>% filter(!is.na(log_sale_price)), aes(x = log_sale_price)) +
  geom_histogram(bins = 40, fill = "blue", color = "black", alpha = 0.7) +
  scale_x_continuous(
    breaks = pretty_breaks(n = 10)
  ) +
  labs(
    title = "Distribucija log_sale_price",
    x = "log10(SALE.PRICE)",
```

```
    y = "Broj nekretnina"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

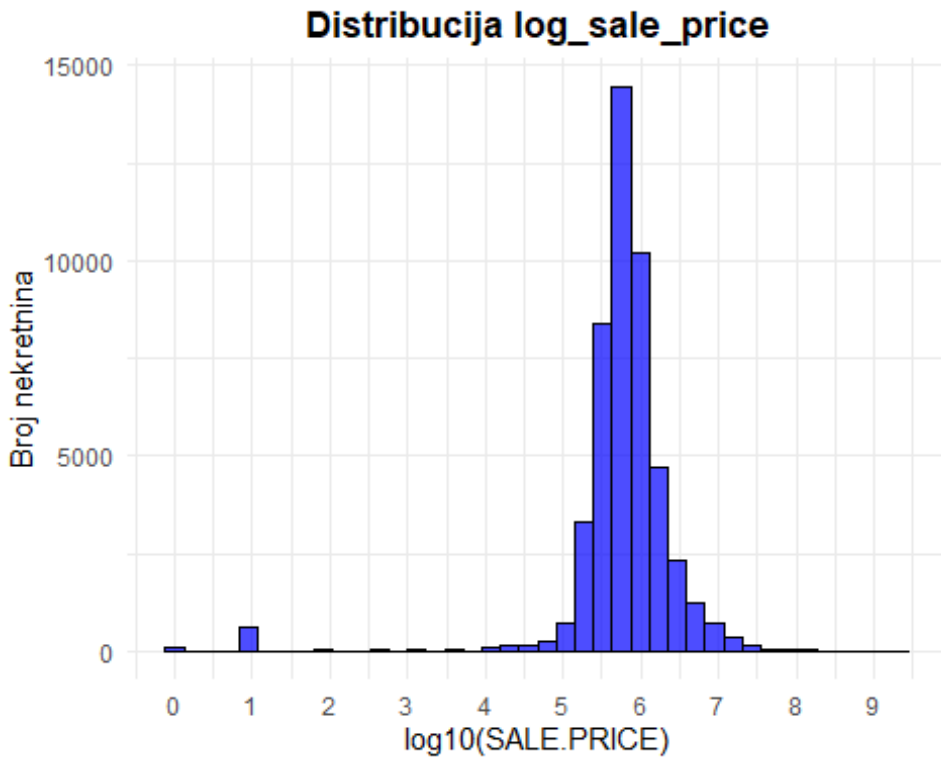

Slično možemo primetiti i kod LAND.SQUARE.FEET i GROSS.SQUARE.FEET da nakon logaritamske transformacije imamo kraći "rep" sa desne strane i sabijenije ekstremno velike vrednosti, pa outlieri imaju manji uticaj. Time dobijamo kompaktniju raspodelu stabilniji i linearniji odnos sa cenom, što olakšava učenje linearnih modela.

```
ggplot(data, aes(x = log_land_sqft)) +
  geom_histogram(bins = 50, color = "black", alpha = 0.7) +
  labs(title = "log_land_sqft", x = "log10(LAND.SQUARE.FEET + 1)", y = "Broj"
) +
  theme_minimal()
```

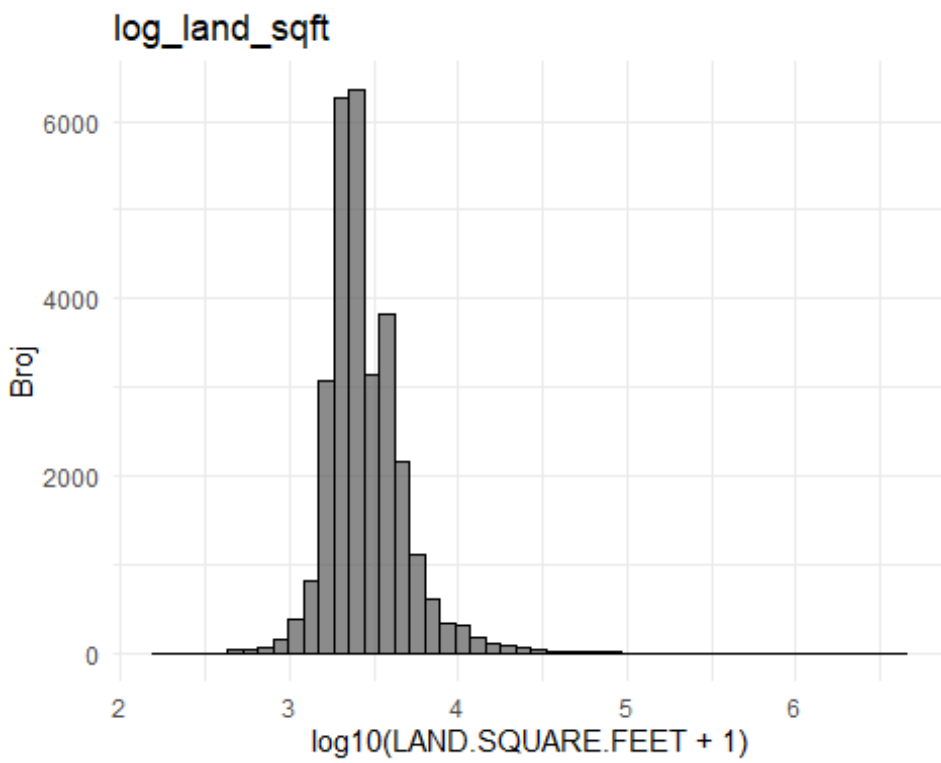


```
ggplot(data, aes(x = log_gross_sqft)) +
  geom_histogram(bins = 50, color = "black", alpha = 0.7) +
  labs(title = "log_gross_sqft", x = "log10(GROSS.SQUARE.FEET + 1)", y = "Bro
j") +
  theme_minimal()
```

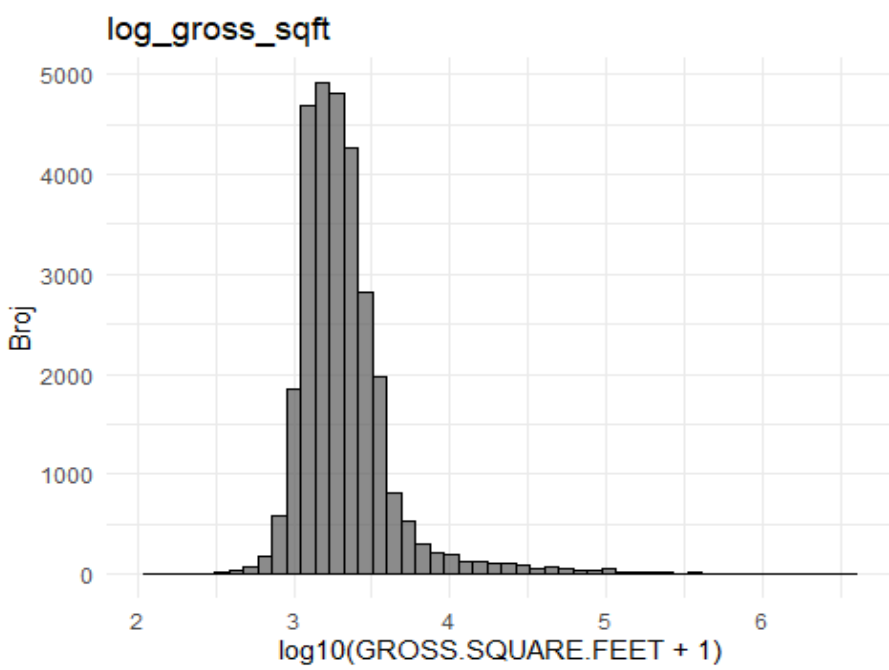

BOROUGH

Grafik pokazuje da neke opštine imaju značajno više zapisa od drugih (neravnomerna raspodela po opštinama). Zbog toga promenljivu BOROUGH tretiramo kao kategorijsku i kod modelovanja je uključujemo putem automatskog one-hot enkodiranja, kako bismo uhvatili razlike između opština.

```
ggplot(data, aes(x = BOROUGH, fill = BOROUGH)) +
  geom_bar(alpha = 0.8) +
  labs(title = "Broj zapisa po BOROUGH", x = "Borough", y = "Broj") +
  theme_minimal() +
  theme(legend.position = "none")
```

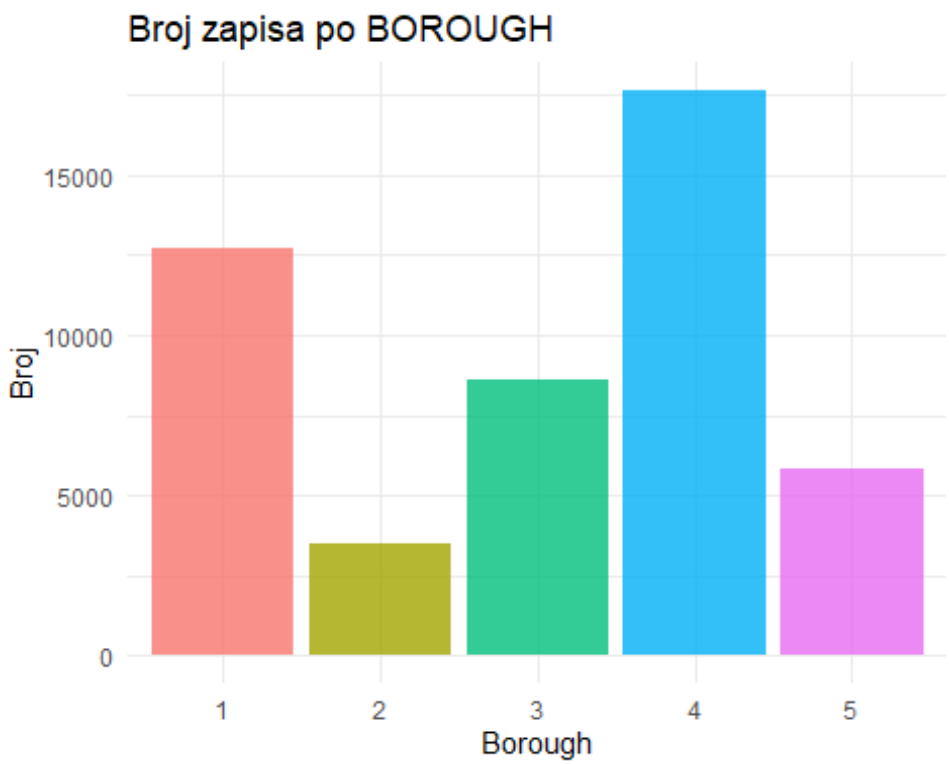

BUILDING.CLASS.CATEGORY

Grafik prikazuje prvih 10 najzastupljenijih kategorija objekata. Primećujemo neravnomernu raspodelu, pa ovu promenljivu tretiramo kao kategorijsku i upotrebićemo je u modelu putem one-hot enkodiranja uz opciju grupisanja kategorija (detaljnije u Feature engineering poglavlju) radi stabilnijeg modelovanja.

```
top10 <- data %>%
  count(BUILDING.CLASS.CATEGORY, sort = TRUE) %>%
  head(10)

ggplot(top10, aes(x = reorder(BUILDING.CLASS.CATEGORY, n), y = n, fill = BUIL
```

```
DING.CLASS.CATEGORY)) +
  geom_col(alpha = 0.8) +
  coord_flip() +
  labs(title = "BUILDING.CLASS.CATEGORY (Top 10)", x = "", y = "Broj zapisa")
+
  theme_minimal() +
  theme(legend.position = "none")
```

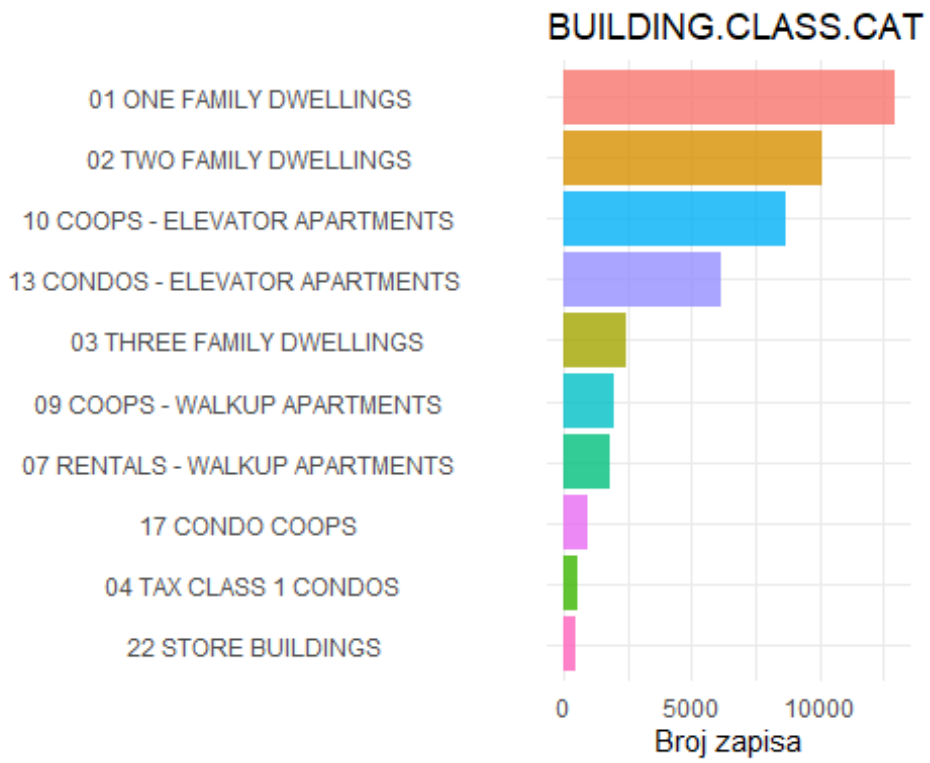

NEIGHBORHOOD

Pošto NEIGHBORHOOD ima mnogo kategorija i neravnomernu raspodelu, njegovo uključivanje u model bi dovelo do velikog broja dummy promenljivih i potencijalno nestabilnog modela. Zato se opredeljujemo za BOROUGH kao grublju, ali robusniju lokacijsku informaciju koja ima malo nivoa, dobro je zastupljena i hvata značajne prostorne razlike u cenama.

```
top10_nbh <- data %>%
  count(NEIGHBORHOOD, sort = TRUE) %>%
  head(10)

ggplot(top10_nbh, aes(x = reorder(NEIGHBORHOOD, n), y = n, fill = NEIGHBORHOO
D)) +
  geom_col(alpha = 0.8) +
  coord_flip() +
  labs(title = "NEIGHBORHOOD (Top 10)", x = "", y = "Broj zapisa") +
```

```
  theme_minimal() +
  theme(legend.position = "none")
```

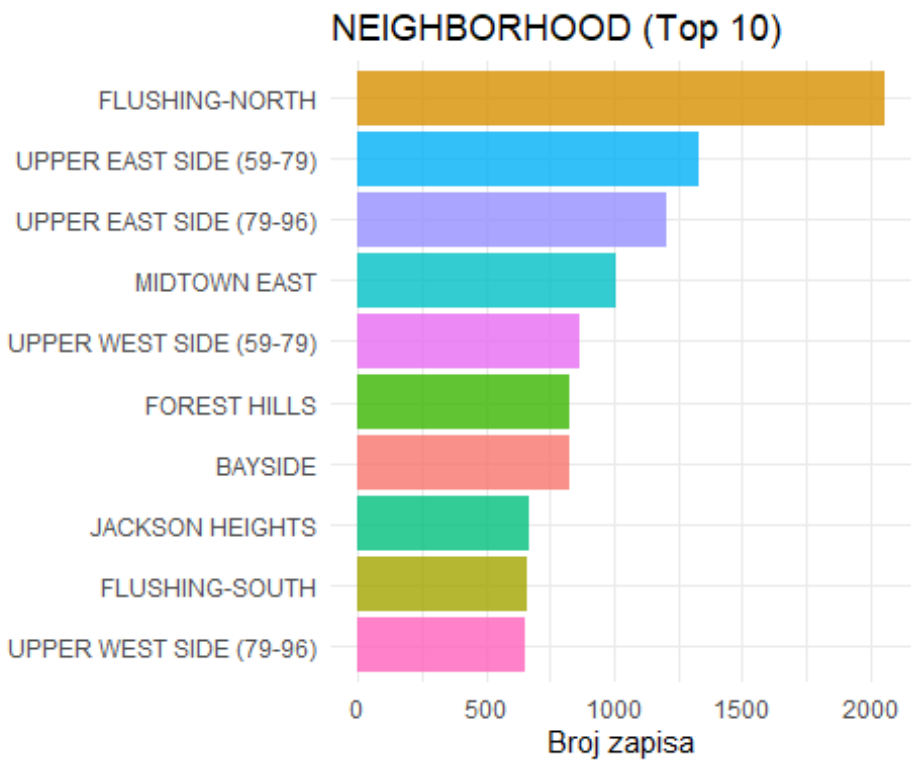

Sada prelazimo na analizu odnosa ostalih relevantnih kolona sa ciljnom SALE.PRICE promenljivom, odnosno na bivarijantnu analizu.

Prvo ćemo pristupiti radu sa numeričkim kolonama.

Bivarijantna analiza

GROSS.SQUARE.FEET

Na grafiku log10(SALE.PRICE) u odnosu na log10(GROSS.SQUARE.FEET+1) primećujemo pozitivnu vezu sa porastom vrednosti obe promenljive. Takođe primećujemo horizontalne grupe vrednosti jer veliki broj zapisa ima iste vrednosti SALE.PRICE (što ukazuje na administrativne transakcije), kao i vertikalne grupe jer GROSS.SQUARE.FEET često ima ponavljane vrednosti.

```
ggplot(data, aes(x = log_gross_sqft, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title="Grafik odnosa SALE.PRICE i GROSS.SQUARE.FEET",
       x="log10(GROSS.SQUARE.FEET+1)", y="log10(SALE.PRICE)") +
  theme_minimal()
```

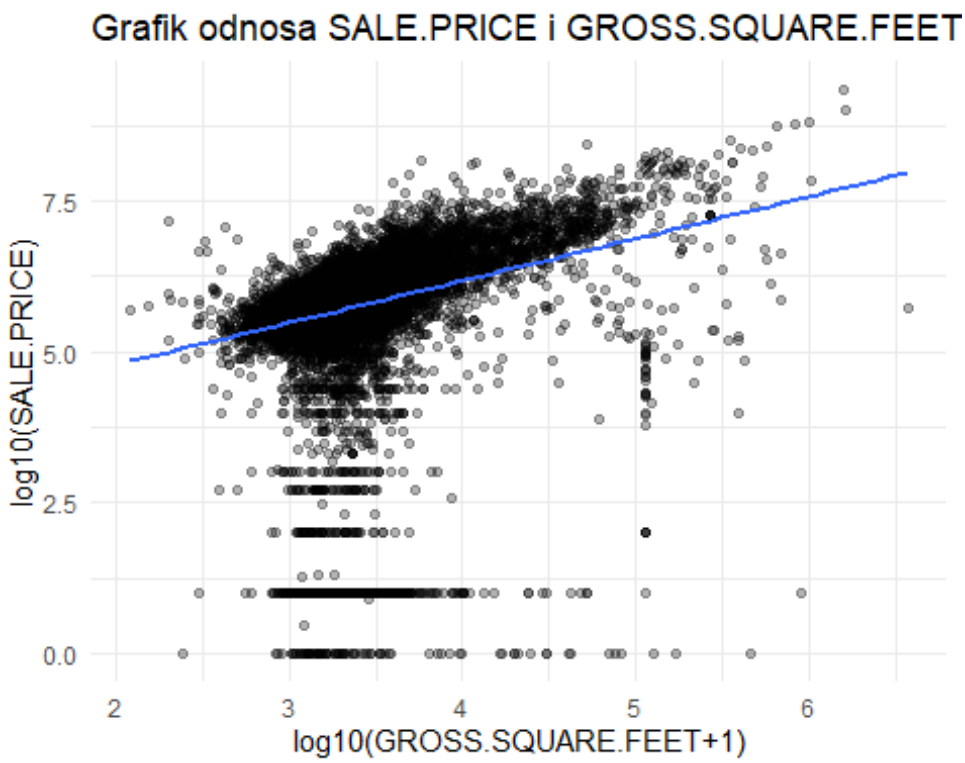

Zadržali smo samo transakcije sa SALE.PRICE > 10000 kako bismo uklonili administrativne prodaje koje ne odražavaju tržišnu vrednost. Time smanjujemo uticaj nerealno malih cena i dobijamo homogeniji skup podataka pogodniji za analizu i predikciju realnih prodajnih cena.

```
data <- data %>%
  filter(SALE.PRICE > 10000)
```

Posledice prethodnog filtriranja možemo primetiti na sada preglednijem grafiku.

Na osnovu analize ovog grafika između SALE.PRICE i GROSS.SQUARE.FEET uočavamo da postoje objekti sa izrazito velikim vrednostima bruto površine. Vrednosti log10(GROSS.SQUARE.FEET+1) veće od 6.2 značajno odstupaju od glavnog skupa podataka i predstavljaju nekretnine sa izuzetno velikom kvadraturom

```
ggplot(data, aes(x = log_gross_sqft, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title="Grafik odnosa SALE.PRICE i GROSS.SQUARE.FEET",
       x="log10(GROSS.SQUARE.FEET+1)", y="log10(SALE.PRICE)") +
  theme_minimal()
```

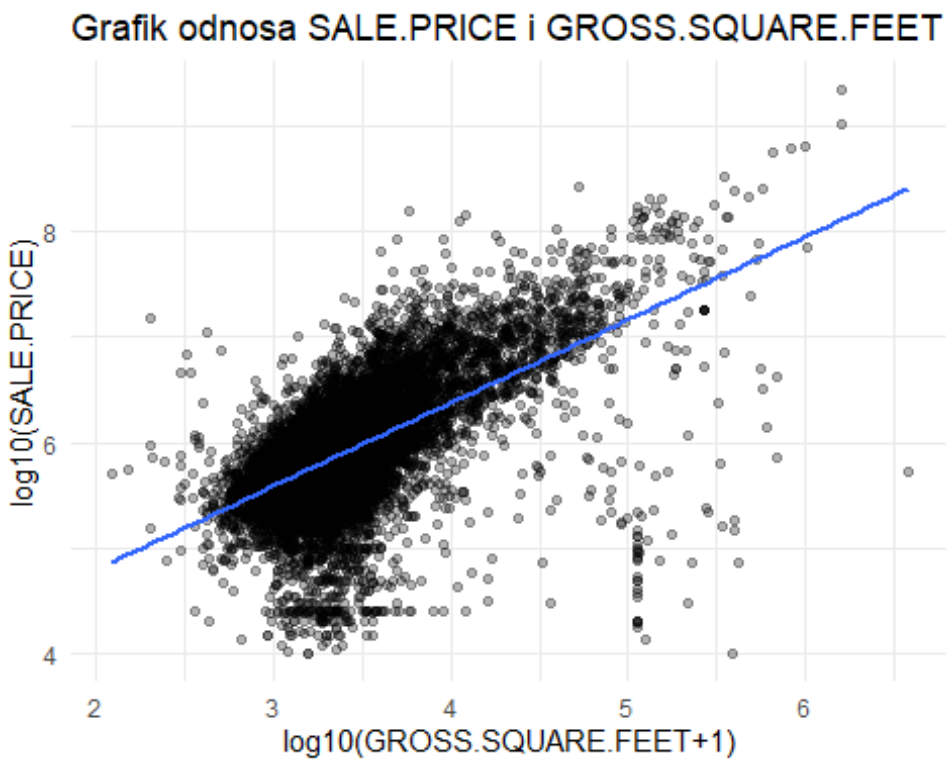

Ove nekretnine se po svojim karakteristikama razlikuju od dominantnog dela uzorka, jer je reč o vrlo velikim objektima (npr. velike komercijalne zgrade) koji ne prate isti obrazac odnosa kvadrature i cene kao tipične stambene jedinice. Njihovo prisustvo može povećati varijansu što smanjuje stabilnost regresionog modela. Iz tog razloga uklanjamo vrednosti kod kojih je log10(GROSS.SQUARE.FEET+1) > 6.2.

```
data <- data %>%
  filter(log_gross_sqft <= 6.2 | is.na(log_gross_sqft))
```

LAND.SQUARE.FEET

Na osnovu analize scatter grafika između SALE.PRICE i LAND.SQUARE.FEET uočavamo da su objekti sa izrazito velikim vrednostima površine zemljišta. Vrednosti log10(LAND.SQUARE.FEET+1) veće od 5.3 značajno odstupaju od glavnog skupa podataka i predstavljaju nekretnine sa izuzetno velikim parcelama.

```
ggplot(data, aes(x = log_land_sqft, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title="Grafik odnosa SALE.PRICE i LAND.SQUARE.FEET",
       x="log10(LAND.SQUARE.FEET+1)", y="log10(SALE.PRICE)") +
  theme_minimal()
```

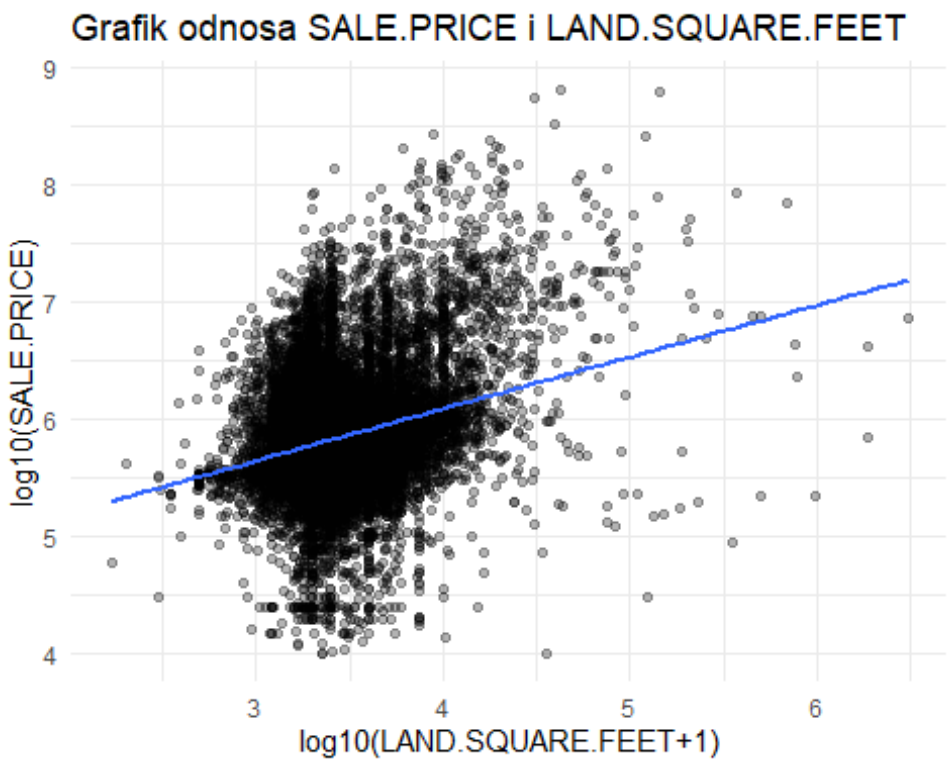

Ove nekretnine se po svojim karakteristikama razlikuju od dominantnog dela uzorka, jer je reč o veoma velikim zemljištima koja ne prate isti tržišni obrazac formiranja cene kao tipične stambene jedinice. Njihovo prisustvo dovodi do povećane varijanse i utiče na stabilnost regresionog modela. Iz tog razloga brišemo podatake tako što uklonjenamo sva posmatranja kod kojih je log10(LAND.SQUARE.FEET+1) veće od 5.3.

```
data <- data %>%
  filter(log_land_sqft <= 5.3 | is.na(log_land_sqft))
```

YEAR.BUILT

Prvo što uočimo kada pogledamo grafik jeste da je većina objekata za koje su zabeležene prodaje izgradjeno posle 1900. Tako da ćemo ukloniti sve vrednosti pre toga i to nisu klasični outlieri.

```
data <- data %>%
  filter(is.na(YEAR.BUILT) | YEAR.BUILT >= 1900)
```

Što se tiče ostalih godina ne vidi se nijedan izdvojen podatak koji bi bio ekstrem u odnosu na ostatak uzorka. Ne postoji nagli prekid, niti izolovana grupa godina koja bi se ponašala potpuno drugačije. Ono što se i dalje vidi jesu vertikalni outlieri u smislu cene, odnosno

pojedinačne vrlo visoke ili vrlo niske vrednosti SALE.PRICE unutar gotovo svih perioda gradnje. Međutim, to nisu outlieri po osnovu godine izgradnje, već po osnovu same cene.

```
ggplot(data, aes(x = YEAR.BUILT, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "loess", se = FALSE) +
  labs(title="Grafik odnosa SALE.PRICE i YEAR.BUILT",
       x="YEAR.BUILT", y="log10(SALE.PRICE)") +
  theme_minimal()

## `geom_smooth()` using formula = 'y ~ x'
```

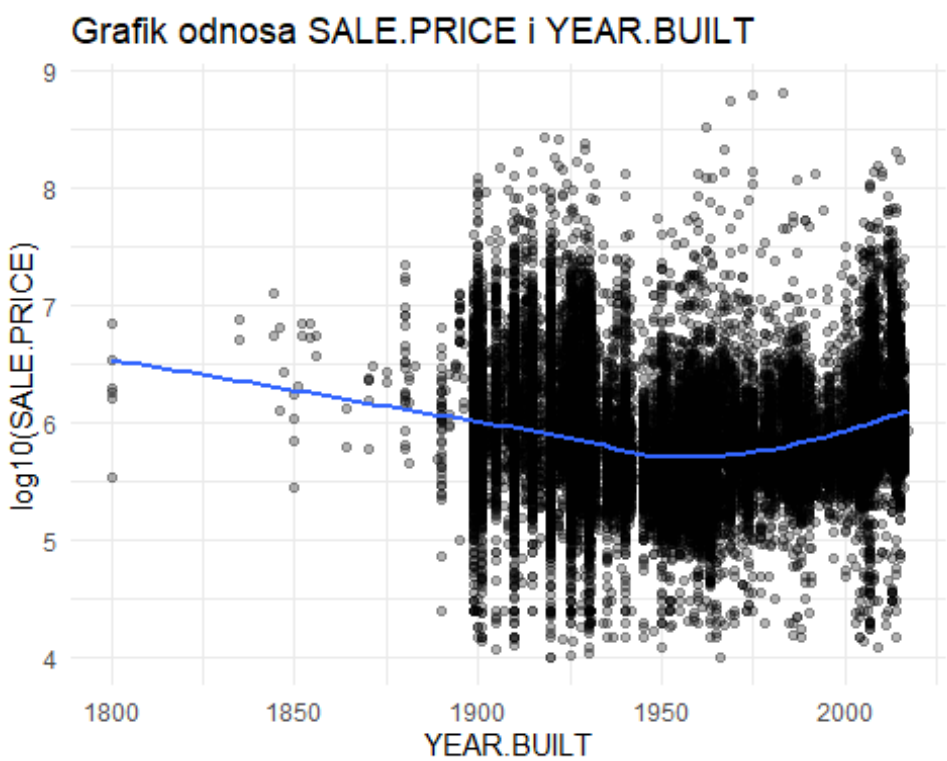

TOTAL.UNITS

Na grafiku koji prikazuje odnos između varijable TOTAL.UNITS i prodajne cene uočava se samo jedna ekstremna tačka koja značajno odstupa od ostatka podataka.

```
ggplot(data, aes(x = TOTAL.UNITS, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title="Grafik odnosa SALE.PRICE i TOTAL.UNITS",
       x="TOTAL.UNITS", y="log10(SALE.PRICE)") +
  theme_minimal()
```

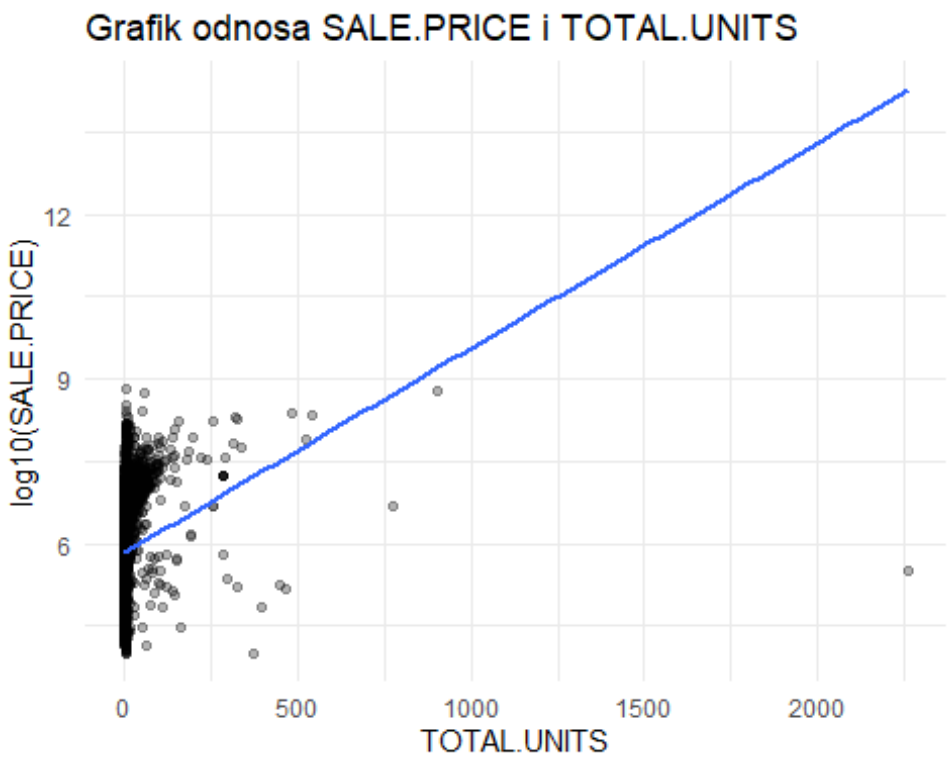

Ta vrednost se nalazi na malo više od 2500 na x osi, dok je najveći deo posmatranih nekretnina koncentrisan na znatno nižim vrednostima. S obzirom na to da je ovaj podatak izolovan i da se ne uklapa u obrazac ostatka skupa podataka, postoji mogućnost da se radi o grešci pri unosu podataka ili o izuzetno specifičnoj transakciji koja nije reprezentativna za tipično tržišno ponašanje. Taj red ćemo izbaciti.

```
data <- data %>%
  filter(is.na(TOTAL.UNITS) | TOTAL.UNITS <= 2000)
```

Sada prelazimo na odnos SALE.PRICE sa relevantnim kategorijskim promenljivama.

BOROUGH

Na grafiku ne uočavamo outliere koji bi se mogli smatrati greškama ili nelogičnim vrednostima u podacima. Iako su prisutne tačke izvan međukvartilni raspona, one su očekivane u kontekstu tržišta nekretnina, gde postoji velika varijabilnost cena, posebno kod luksuznih i specifičnih objekata. Pored toga, može se primetiti da su medijane prodajnih cena relativno slične među svim gradskim opštinama.

```
ggplot(data, aes(x = BOROUGH, y = SALE.PRICE)) +
  geom_boxplot(outlier_alpha = 0.3) +
  scale_y_log10(labels = comma) +
```

```
  labs(title="SALE.PRICE po BOROUGH", x="BOROUGH", y="SALE.PRICE") +
  theme_minimal()
```

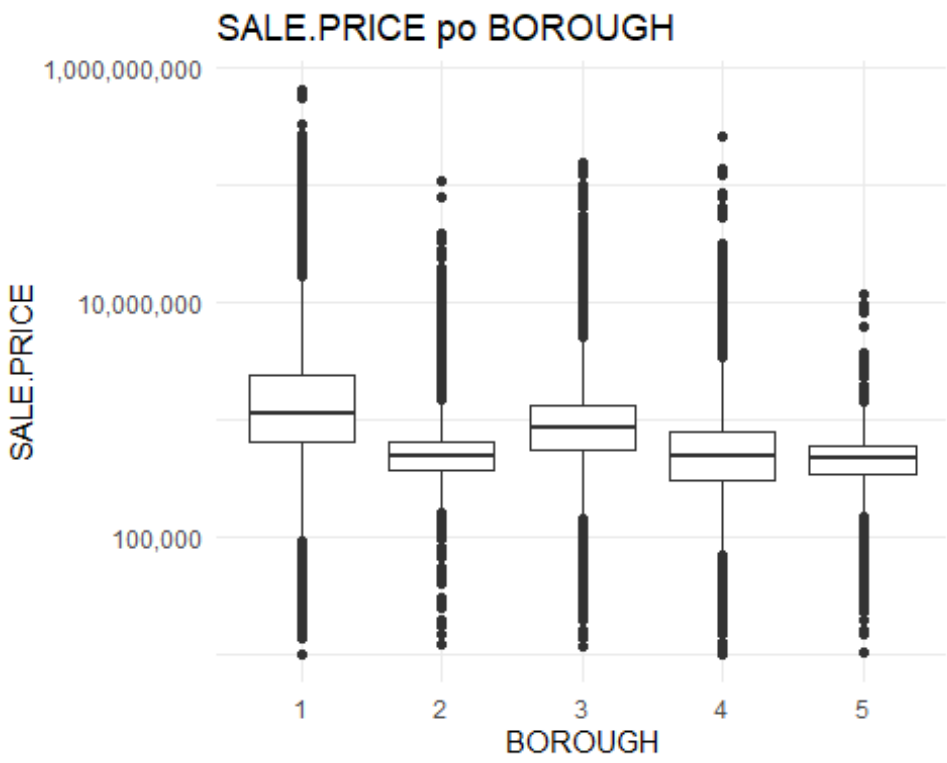

BUILDING.CLASS.CATEGORY

Radi lakšeg prikaza podataka uzećemo samo top 10 kategorija koje se pojavljuju u kupovinama.

```
top10_kat <- data %>%
  count(BUILDING.CLASS.CATEGORY, sort = TRUE) %>%
  slice_head(n = 10) %>%
  pull(BUILDING.CLASS.CATEGORY)
```

Outliere koje vidimo na grafiku nećemo uklanjati zato što na tržištu nekretnina ekstremne vrednosti SALE.PRICE često predstavljaju realne i legitimne transakcije, a ne greške u podacima kao što je bio slučaj kod BOROUGH. Tržište nekretnina je prirodno heterogeno, sa velikim razlikama u lokaciji, kvadraturi, stanju objekta, nameni i luksuzu, što dovodi do širokog raspona cena čak i unutar iste kategorije objekata. Uklanjanje takvih vrednosti bez jasnog razloga moglo bi dovesti do pristrasnosti u analizi. Outlieri bi trebalo da se uklanjaju samo u slučaju da postoji dokaz da su posledica greške pri unosu podataka, administrativne anomalije ili transakcije koje nisu uporedive sa ostalima.

```r
ggplot(filter(data, BUILDING.CLASS.CATEGORY %in% top10_kat),
       aes(x = BUILDING.CLASS.CATEGORY, y = SALE.PRICE)) +
  geom_boxplot(outlier_alpha = 0.25) +
  scale_y_log10(labels = comma) +
  labs(title="SALE.PRICE po BUILDING.CLASS.CATEGORY",
       x="Kategorija", y="SALE.PRICE") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

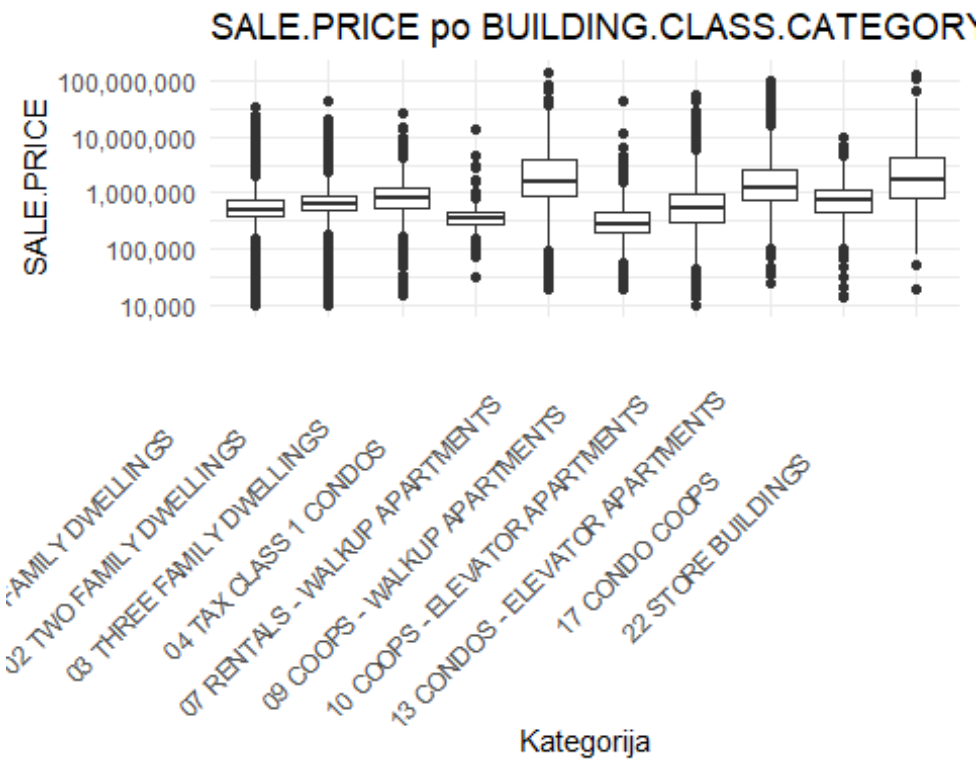

BUILDING.CLASS.AT.TIME.OF.SALE

Kod BUILDING.CLASS.AT.TIME.OF.SALE uzećemo isto samo prvih 10 redova kao i kod BUILDING.CLASS i uočićemo sličnu stvar, outlieri predstavljaju realne tržišne razlike između tipova objekata, pa ih ne uklanjamo jer ne postoje dokazi da su posledica greške.

```r
top10_klasa_nekretnine <- names(
  sort(table(data$BUILDING.CLASS.AT.TIME.OF.SALE), decreasing = TRUE)[1:10]
)

data_top10_pomocna <- data %>%
  filter(BUILDING.CLASS.AT.TIME.OF.SALE %in% top10_klasa_nekretnine)

ggplot(data_top10_pomocna,
       aes(x = BUILDING.CLASS.AT.TIME.OF.SALE, y = SALE.PRICE)) +
  geom_boxplot(outlier_alpha = 0.3) +
  scale_y_log10(labels = comma) +
```

```
  labs(
    title = "SALE.PRICE BUILDING.CLASS.AT.TIME.OF.SALE",
    x = "BUILDING.CLASS.AT.TIME.OF.SALE",
    y = "SALE.PRICE"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    axis.text.x = element_text(angle = 45, hjust = 1)
  )
```

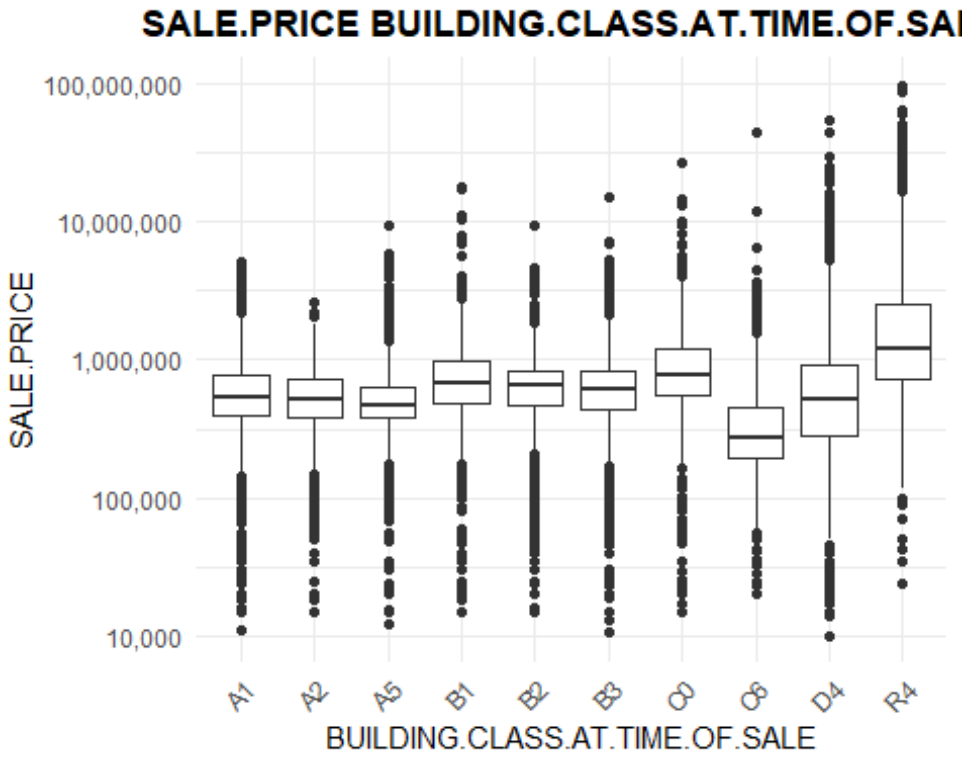

TAX.CLASS.AT.TIME.OF.SALE

Kod obeležja TAX.CLASS.AT.TIME.OF.SALE uočeni ekstremi u okviru boxplot-a predstavljaju realne razlike u tržišnim cenama između poreskih klasa, te ih ne treba uklanjati jer ne ukazuju na greške već na prirodnu varijabilnost podataka kao i kod svih prethodnih kategorijskih kolona.

```
ggplot(data, aes(x = TAX.CLASS.AT.TIME.OF.SALE, y = SALE.PRICE)) +
  geom_boxplot(outlier_alpha = 0.3) +
  scale_y_log10(labels = comma) +
  labs(title="SALE.PRICE po TAX.CLASS.AT.TIME.OF.SALE",
```

```
      x="TAX.CLASS.AT.TIME.OF.SALE", y="SALE.PRICE") +
  theme_minimal()
```

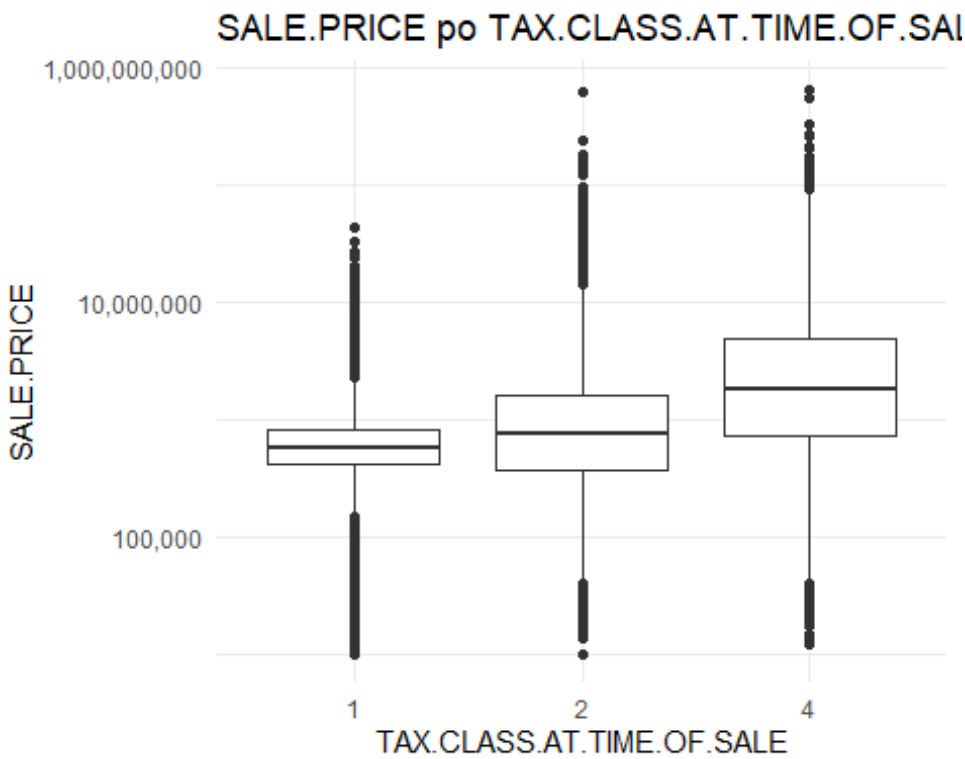

Multivarijantna analiza

SALE.PRICE, GROSS.SQUARE.FEET i BOROUGH

Vidi se da veća površina uglavnom znači veću cenu, ali taj odnos nije isti u svim opštinama. U nekima cena raste brže sa porastom površine, dok je u drugima taj uticaj slabiji.

Zato ima smisla da se u model uključi interakcija između GROSS.SQUARE.FEET i BOROUGH, jer efekat veličine nekretnine očigledno zavisi od opštine.

```
ggplot(data, aes(x = log_gross_sqft,
                 y = log_sale_price,
                 color = BOROUGH)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    title = "Odnos povrsine i cene po opštinama",
    x = "log GROSS.SQUARE.FEET",
    y = "log SALE.PRICE",
    color = "BOROUGH"
```

```
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold")
  )
```

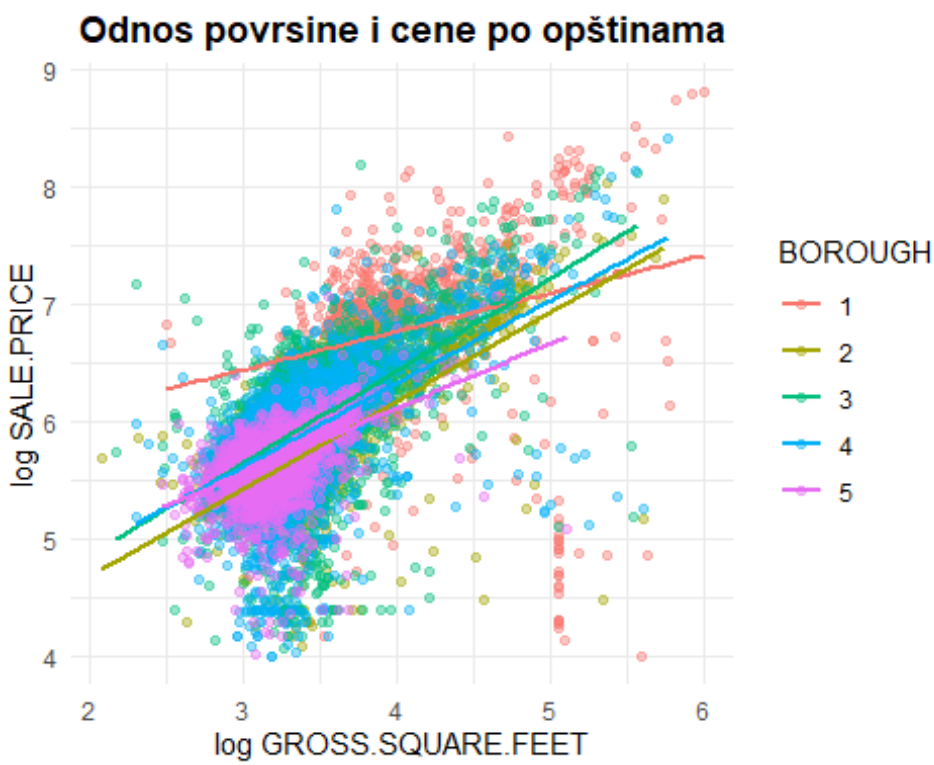

SALE.PRICE, LAND.SQUARE.FEET i BOROUGH

Kao i kod GROSS površine veća površina uglavnom znači višu cenu, ali taj efekat varira između opština, pa treba uključiti interakciju između LAND.SQUARE.FEET i BOROUGH jer uticaj kvadrature zavisi od lokacije.

```
ggplot(data, aes(x = log_land_sqft,
                 y = log_sale_price,
                 color = BOROUGH)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    title = "Odnos povrsine i cene po opštinama",
    x = "log LAND.SQUARE.FEET",
    y = "log SALE.PRICE",
    color = "BOROUGH"
  ) +
  theme_minimal() +
```

```
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold")
  )
```

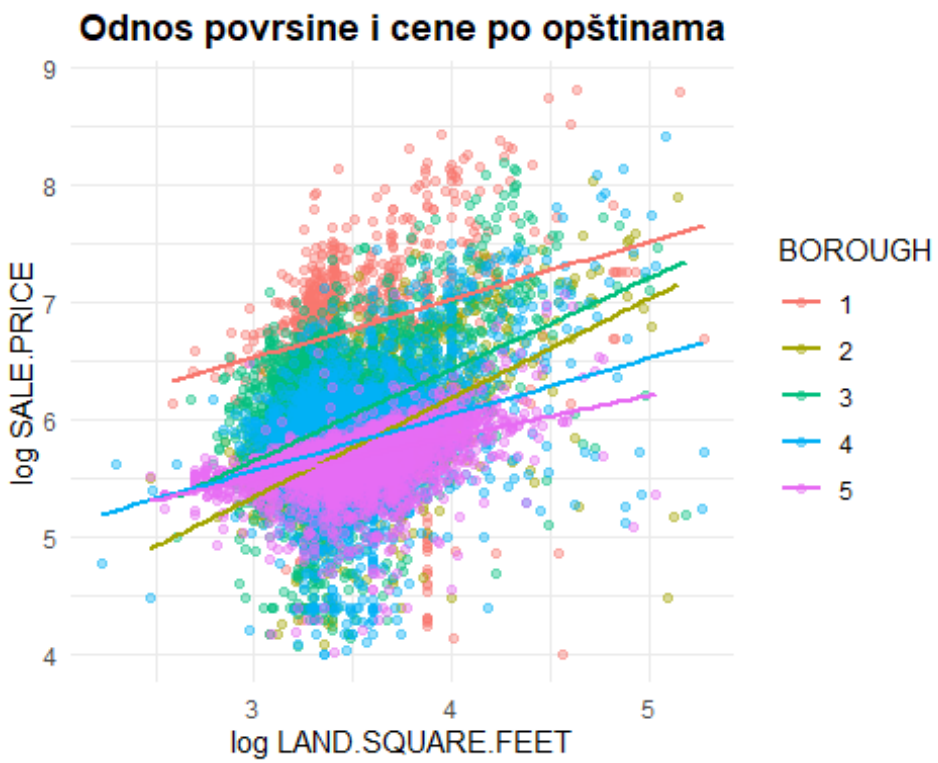

Imputacija vrednosti

Pošto smo u kolonama LAND.SQUARE.FEET i GROSS.SQUARE.FEET imali veliki broj nedostajućih vrednosti i njih zamenili sa NA vrednostima zarad transformacije tipova kolona u numeričke, sada ćemo izvršiti pomenutu imputaciju podataka po BUILDING.CLASS.CATEGORY.

```
sum(is.na(data$LAND.SQUARE.FEET))

## [1] 18777

sum(is.na(data$GROSS.SQUARE.FEET))

## [1] 18933
```

Da bi smo odredili da li ćemo za popunjavanje ovih vrednosti koristiti mean ili median vrednosti potrebno je da prvo odradimo Shapiro test i vidimo kakva nam je raspodela za ove kolone.

Međutim, zbog velikog broj redova mi nećemo moći da iskoristimo ovaj test koji podržava od 3 do 5000 redova, pa se opredeljujemo za Anderson-Darling test normalnosti koji nam omogućava da proverimo normalnost našeg velikog uzorka: ako je p-value > 0.05 raspodela je približno normalna, a ako je p-value <= 0.05 raspodela nije normalna.

```
ad.test(na.omit(data$LAND.SQUARE.FEET))

##
##  Anderson-Darling normality test
##
## data:  na.omit(data$LAND.SQUARE.FEET)
## A = 4985, p-value < 2.2e-16

ad.test(na.omit(data$GROSS.SQUARE.FEET))

##
##  Anderson-Darling normality test
##
## data:  na.omit(data$GROSS.SQUARE.FEET)
## A = 8363.4, p-value < 2.2e-16
```

Rezultati Anderson–Darling testa su nam ukazali da LAND.SQUARE.FEET i GROSS.SQUARE.FEET ne prate normalnu raspodelu (jer je p-value < 2.2e-16), što ukazuje na asimetriju i prisustvo ekstremnih vrednosti. Zbog toga za imputaciju u obe kolone koristimo medijanu kao robusniju meru.

Takođe, uvodimo indikatorske promenljive imp_land i imp_gross koje beleže da li je vrednost originalno nedostajala. Ovo je korisno jer nedostajuće vrednosti često nisu slučajne (određene klase zgrada ili borough-i češće nemaju upisane kvadrature). Dodavanjem ovih flag-ova model kasnije može da zna da je vrednost imputovana i time smanjujemo rizik da imputacija unese pristrasnost u analizu.

```
data <- data %>%
  mutate(
    imp_land = as.integer(is.na(LAND.SQUARE.FEET)),
    imp_gross = as.integer(is.na(GROSS.SQUARE.FEET))
  )
```

Grupisanjem po lokaciji i tipu objekta dobijamo realističnije tipične kvadrature nego kada bismo koristili jednu globalnu vrednost za ceo skup.

```
grp_medians <- data %>%
  group_by(BOROUGH, BUILDING.CLASS.CATEGORY) %>%
  summarise(
    med_land  = median(LAND.SQUARE.FEET,  na.rm = TRUE),
    med_gross = median(GROSS.SQUARE.FEET, na.rm = TRUE),
    .groups = "drop"
  )
```

U pojedinim grupama može se desiti da sve vrednosti budu NA (retke kombinacije borough-a i kategorije), pa medijana unutar te grupe ne može da se izračuna. Zato uvodimo globalne medijane kao fallback rešenje.

```
global_med_land  <- median(data$LAND.SQUARE.FEET,  na.rm = TRUE)
global_med_gross <- median(data$GROSS.SQUARE.FEET, na.rm = TRUE)


data <- data %>%
  left_join(grp_medians, by = c("BOROUGH", "BUILDING.CLASS.CATEGORY")) %>%
  mutate(
    LAND.SQUARE.FEET  = ifelse(is.na(LAND.SQUARE.FEET),
                               ifelse(is.na(med_land),  global_med_land,  med
_land),
                               LAND.SQUARE.FEET),
    GROSS.SQUARE.FEET = ifelse(is.na(GROSS.SQUARE.FEET),
                               ifelse(is.na(med_gross), global_med_gross, med
_gross),
                               GROSS.SQUARE.FEET)
  ) %>%
  select(-med_land, -med_gross)
```

Finalnom proverom smo ustanovili da smo uspešno popunili odgovarajuće NA vrednosti.

```
sum(is.na(data$LAND.SQUARE.FEET))

## [1] 0

sum(is.na(data$GROSS.SQUARE.FEET))

## [1] 0
```

Eksplorativna analiza podataka (EDA)

Prilikom istraživačke analize podataka fokusirali smo se na atribute koji, prema domenskom znanju i logici tržišta nekretnina imaju značajan uticaj na prodajnu cenu:

Veličina objekta i zemljišta: Veća kvadratura najčešće podrazumeva i višu cenu, pa su kao ključni atributi analizirani GROSS.SQUARE.FEET, LAND.SQUARE.FEET, kao i broj jedinica (TOTAL.UNITS, RESIDENTIAL.UNITS, COMMERCIAL.UNITS).

Starost objekta: Noviji objekti često imaju veću tržišnu vrednost zbog boljeg stanja i savremenije gradnje, pa je relevantan atribut YEAR.BUILT.

Lokacija: Lokacija predstavlja jedan od najvažnijih faktora u formiranju cene, zbog čega su analizirani atributi BOROUGH, NEIGHBORHOOD i ZIP.CODE.

Tip i namena objekta: Različite vrste nekretnina imaju značajno različite cenovne nivoe, pa su praćeni atributi BUILDING.CLASS.CATEGORY i BUILDING.CLASS.AT.TIME.OF.SALE.
Poreska klasifikacija: Poreski razred može indirektno ukazivati na tip i vrednost objekta, zbog čega je analiziran atribut TAX.CLASS.AT.TIME.OF.SALE.

Vremenski faktor: Kretanje cena kroz vreme je važno za uočavanje trendova, pa je analiziran atribut SALE.DATE.

GROSS.SQUARE.FEET

```
ggplot(data, aes(x = GROSS.SQUARE.FEET, y = SALE.PRICE)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE)+
  scale_y_continuous(labels = comma) +
  labs(title = "GROSS.SQUARE.FEET i SALE.PRICE",
       x = "Bruto površina",
       y = "Prodajna cena") +
  theme_minimal()

## `geom_smooth()` using formula = 'y ~ x'
```

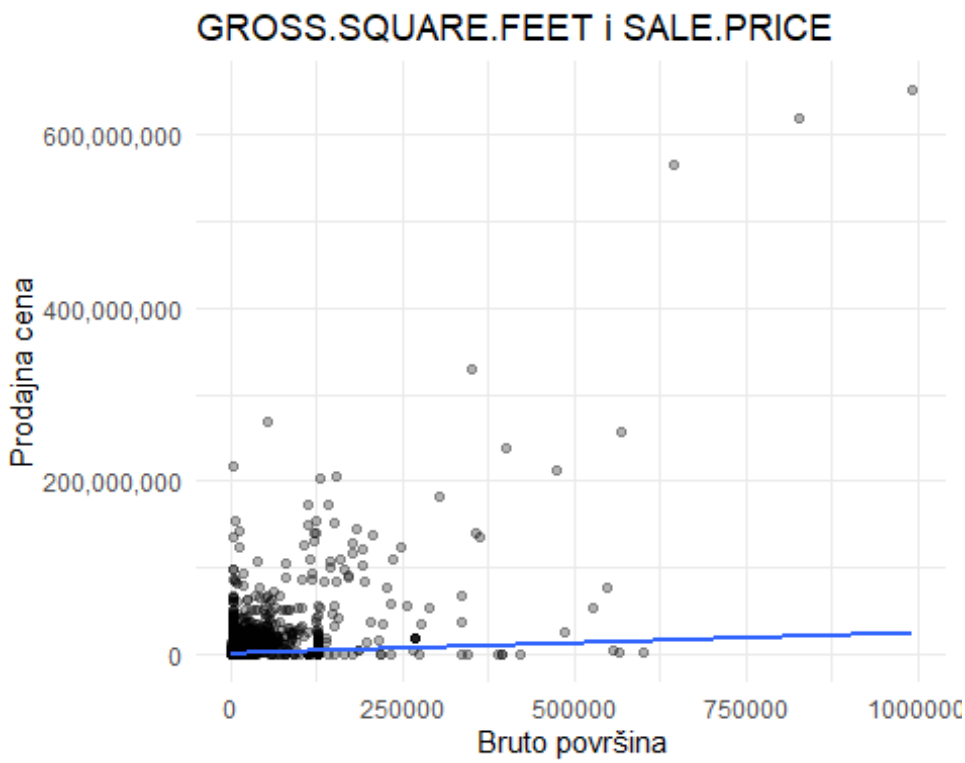

Na grafiku se uočava jedna ekstremno visoka vrednost prodajne cene koja predstavlja outlier u odnosu na ostatak uzorka. Takođe, nekoliko objekata sa izrazito velikom površinom predstavljaju high leverage tačke, jer zbog ekstremnih vrednosti nezavisne promenljive mogu imati značajan uticaj na procenjenu regresionu liniju. Zbog prisustva

ovih ekstremnih vrednosti većina ostalih tačaka je sabijena u donjem levom delu grafika. Zato ćemo zumirati grafik kako bi jasnije videli strukturu podataka u opsegu gde se nalazi najveći broj podataka. Nakon zumiranja jasno se uočava pozitivan trend sa porastom površine raste i prodajna cena (SALE.PRICE), što potvrđuje postojanje pozitivne linearne veze između ove dve promenljive.

```
ggplot(data, aes(x = GROSS.SQUARE.FEET, y = SALE.PRICE)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  scale_y_continuous(labels = comma) +
  coord_cartesian(xlim = c(0, 20000),
                  ylim = c(0, 5000000)) +
  labs(title = "GROSS.SQUARE.FEET i SALE.PRICE",
       x = "Bruto površina",
       y = "Prodajna cena") +
  theme_minimal()
```

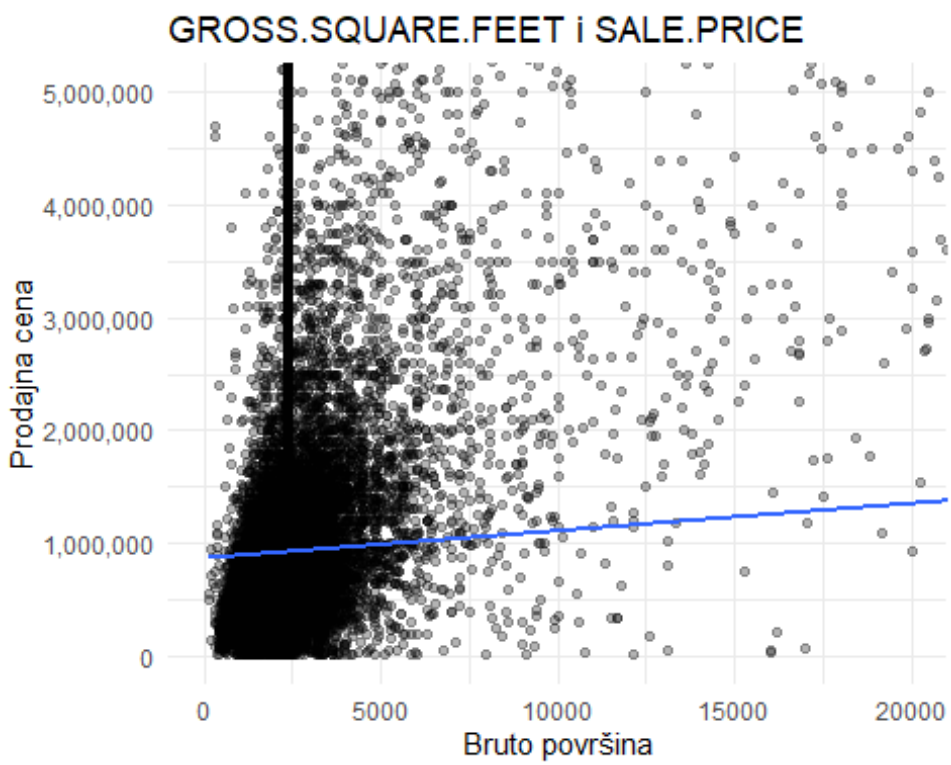

Pearson-ov test (korelacije) meri jačinu i pravac linearnog odnosa između dve numeričke promenljive. p-vrednost pokazuje da li je taj odnos statistički značajan. U našem slučaju p-value je manje od 0.05 tako da je log_gross_sqft statistički značajno obeležje.

```
cor.test(data$log_gross_sqft, data$log_sale_price)

##
##  Pearson's product-moment correlation
```

```
##
## data:  data$log_gross_sqft and data$log_sale_price
## t = 133.27, df = 27118, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.6218304 0.6362146
## sample estimates:
##       cor
## 0.6290764
```

LAND.SQUARE.FEET

```r
ggplot(data, aes(x = log_land_sqft, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    title = "log(LAND.SQUARE.FEET) vs log(SALE.PRICE)",
    x = "log(1 + LAND.SQUARE.FEET)",
    y = "log(1 + SALE.PRICE)"
  ) +
  theme_minimal()
```

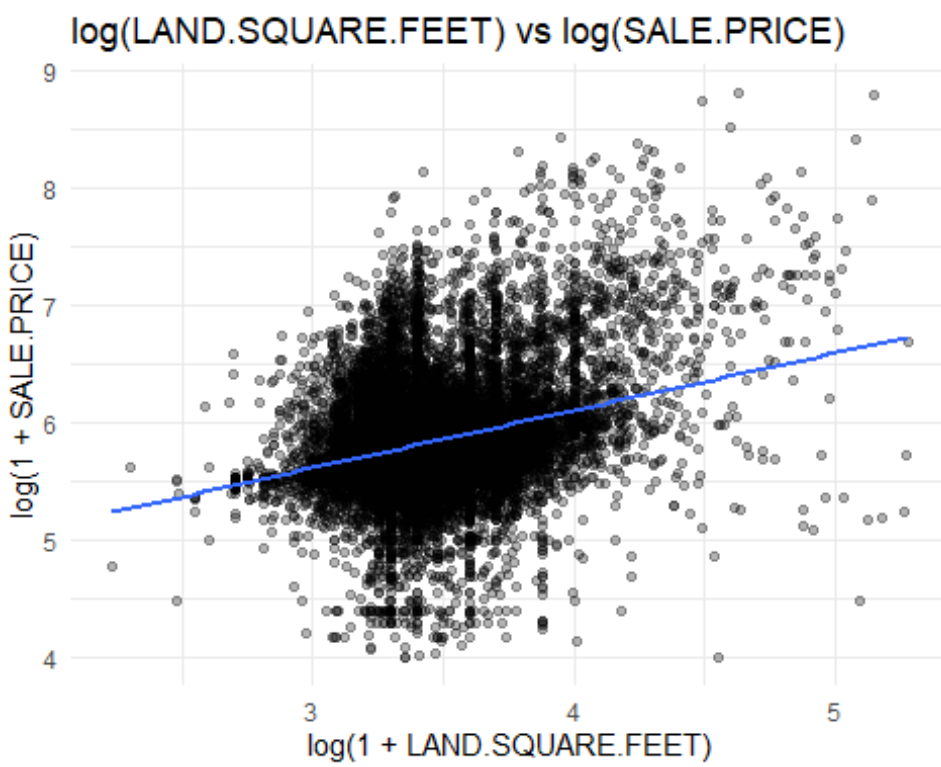


```r
xlim <- quantile(data$log_land_sqft, probs = c(0.01, 0.99), na.rm = TRUE)
ylim <- quantile(data$log_sale_price, probs = c(0.01, 0.99), na.rm = TRUE)

ggplot(data, aes(x = log_land_sqft, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
```

```
  geom_smooth(method = "lm", se = FALSE) +
  coord_cartesian(xlim = xlim, ylim = ylim) +
  labs(
    title = "log(LAND.SQUARE.FEET) vs log(SALE.PRICE) (1–99% zoom)",
    x = "log(1 + LAND.SQUARE.FEET)",
    y = "log(1 + SALE.PRICE)"
  ) +
  theme_minimal()
```

```
## `geom_smooth()` using formula = 'y ~ x'

## Warning: Removed 18777 rows containing non-finite outside the scale range
## (`stat_smooth()`).

## Warning: Removed 18777 rows containing missing values or values outside th
e scale range
## (`geom_point()`).
```

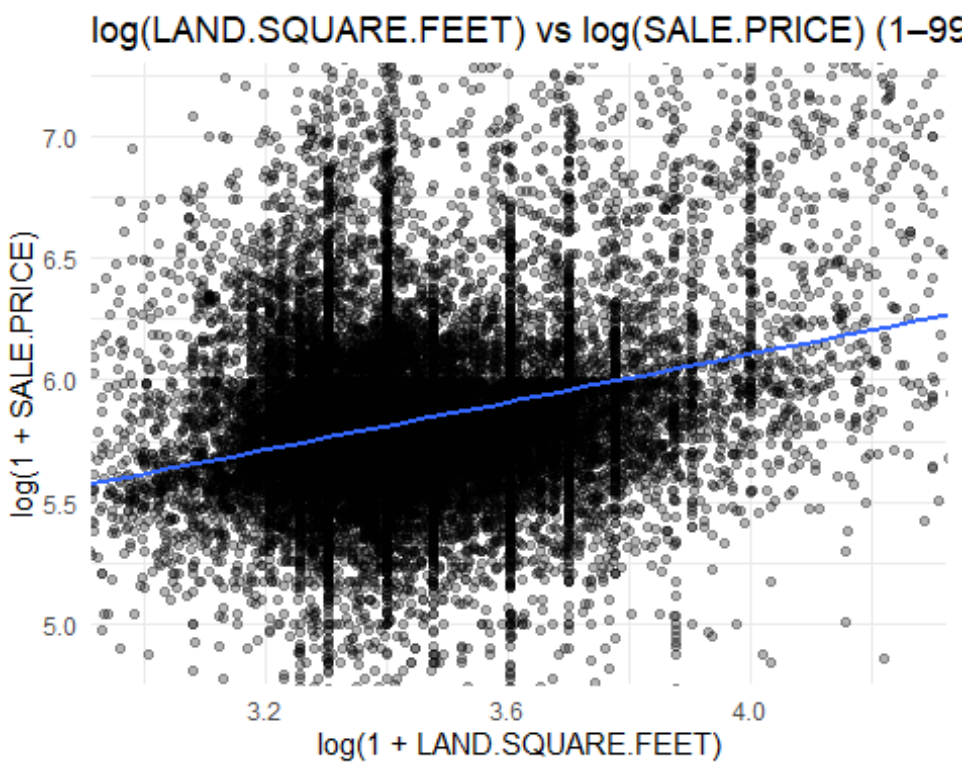

Kao i kod prošlog grafa imamo neke velike vrednosti i to će se uvek dešavati, tako da ćemo nadalje uvek zumirati naše scatter grafove.

Postoji slaba pozitivna veza, ali LAND.SQUARE.FEET mnogo slabije objašnjava SALE.PRICE u poređenju sa GROSS.SQUARE.FEET.

Kao i za log_gross_sqft, pokrenućemo Pearson-ov test i za log_land_sqft. U našem slučaju p-value je manje od 0.05 tako da je log_land_sqft statistički značajno obeležje.

```r
cor.test(data$log_land_sqft, data$log_sale_price)
```

```
##
##  Pearson's product-moment correlation
##
## data:  data$log_land_sqft and data$log_sale_price
## t = 51.014, df = 27274, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.2842654 0.3059333
## sample estimates:
##       cor
## 0.2951373
```

BOROUGH

```r
ggplot(data, aes(x = BOROUGH, y = log_sale_price)) +
  geom_boxplot() +
  scale_y_continuous(labels = comma) +
  labs(title = "SALE.PRICE po BOROUGH",
       x = "BOROUGH",
       y = "Prodajna cena") +
  theme_minimal()
```

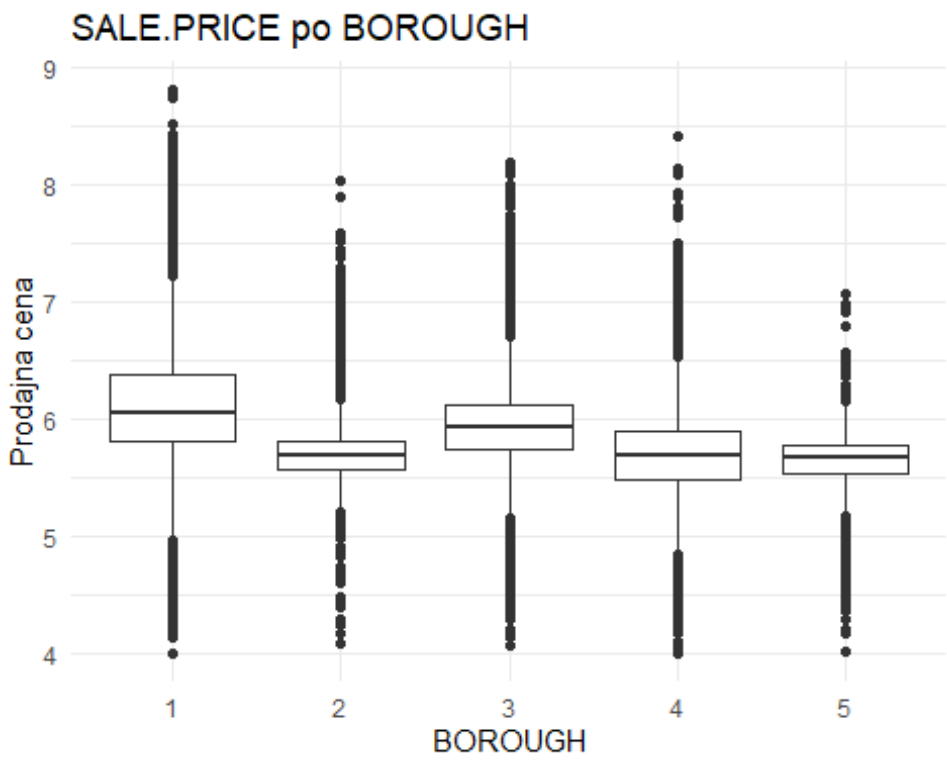

Ovde smo koristili log_sale_price umesto SALE_PRICE radi preglednosti grafika. Može se uočiti da BOROUGH 1 ima najvišu medijanu prodajne cene, kao i najveću varijabilnost, što ukazuje na širi raspon cena i prisustvo luksuznih nekretnina. BOROUGH 3 takođe ima relativno visoke cene, ali niže u poređenju sa BOROUGH 1. BOROUGH 2, 4 i 5 imaju niže medijane i manju odstupanje cena, što ukazuje na stabilnije i ujednačenije tržište nekretnina u tim opštinama.

ANOVA testira da li se prosečne vrednosti numeričke promenljive razlikuju između više kategorija. Ako je p-vrednost manja od 0.05, razlike su statistički značajne što je i slučaj kod nas.

```
anova_borough <- aov(log_sale_price ~ BOROUGH, data = data)
summary(anova_borough)

##                Df Sum Sq Mean Sq F value Pr(>F)
## BOROUGH         4   1715   428.8    2960 <2e-16 ***
## Residuals   46048   6671     0.1
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

BUILDING.CLASS.CATEGORY

```
top10_kategorije <- names(
  sort(table(data$BUILDING.CLASS.CATEGORY), decreasing = TRUE)[1:10]
)
```

```r
data_top10_pomocna <- data %>%
  filter(BUILDING.CLASS.CATEGORY %in% top10_kategorije)

ggplot(data_top10_pomocna,
       aes(x = BUILDING.CLASS.CATEGORY, y = log_sale_price)) +
  geom_boxplot(outlier_alpha = 0.3) +
  scale_y_continuous(labels = comma) +
  labs(
    title = "SALE.PRICE po BUILDING.CLASS.CATEGORY (Top 10)",
    x = "BUILDING.CLASS.CATEGORY",
    y = "SALE.PRICE"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    axis.text.x = element_text(angle = 45, hjust = 1)
  )
```

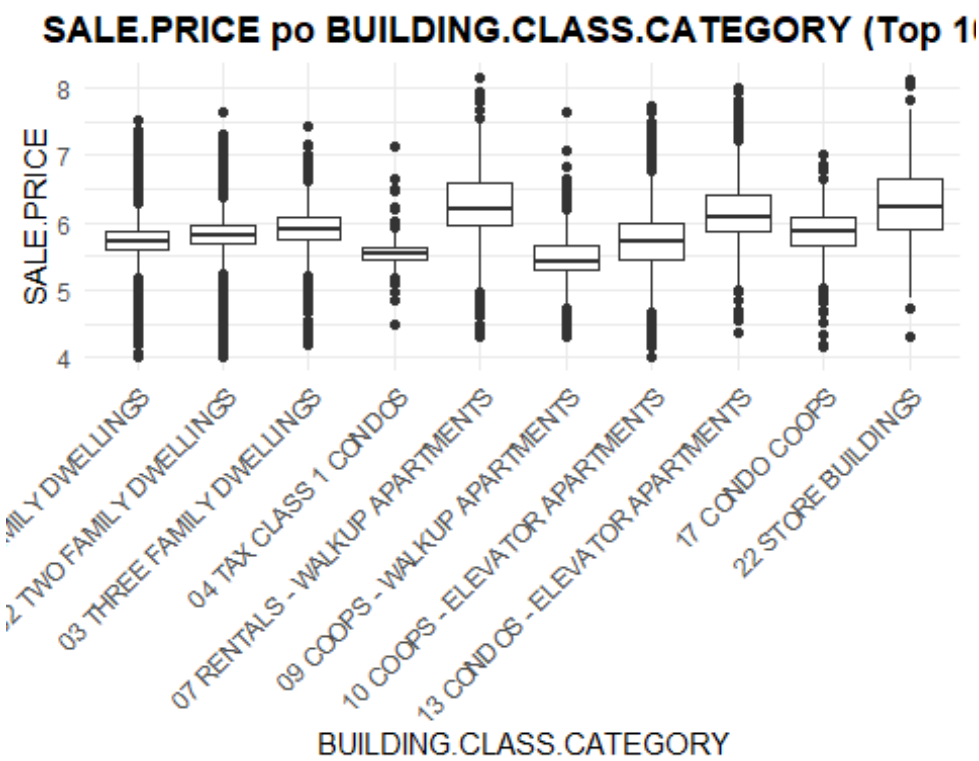

Na grafiku se može uočiti da se medijane cena razlikuju u zavisnosti od tipa objekta. Najviše medijane imaju kategorije kao što su 09 COOPS – WALKUP APARTMENTS, 10 COOPS – ELEVATOR APARTMENTS i 13 CONDOS – ELEVATOR APARTMENTS, što ukazuje da su stanovi u zgradama sa liftom i kooperativni stanovi generalno skuplji. Takođe, 22 STORE BUILDINGS pokazuje relativno visoku medijanu.

```r
top10_kalsa_nekretnine <- names(
  sort(table(data$BUILDING.CLASS.AT.TIME.OF.SALE), decreasing = TRUE)[1:10]
)

data_top10_pomocna <- data %>%
  filter(BUILDING.CLASS.AT.TIME.OF.SALE %in% top10_kalsa_nekretnine)

ggplot(data_top10_pomocna,
       aes(x = BUILDING.CLASS.AT.TIME.OF.SALE, y = log_sale_price)) +
  geom_boxplot(outlier_alpha = 0.3) +
  scale_y_continuous(labels = comma) +
  labs(
    title = "SALE.PRICE po BUILDING.CLASS.AT.TIME.OF.SALE (Top 10)",
    x = "BUILDING.CLASS.AT.TIME.OF.SALE",
    y = "SALE.PRICE"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    axis.text.x = element_text(angle = 45, hjust = 1)
  )

## Warning in geom_boxplot(outlier_alpha = 0.3): Ignoring unknown parameters:
## `outlier_alpha`
```

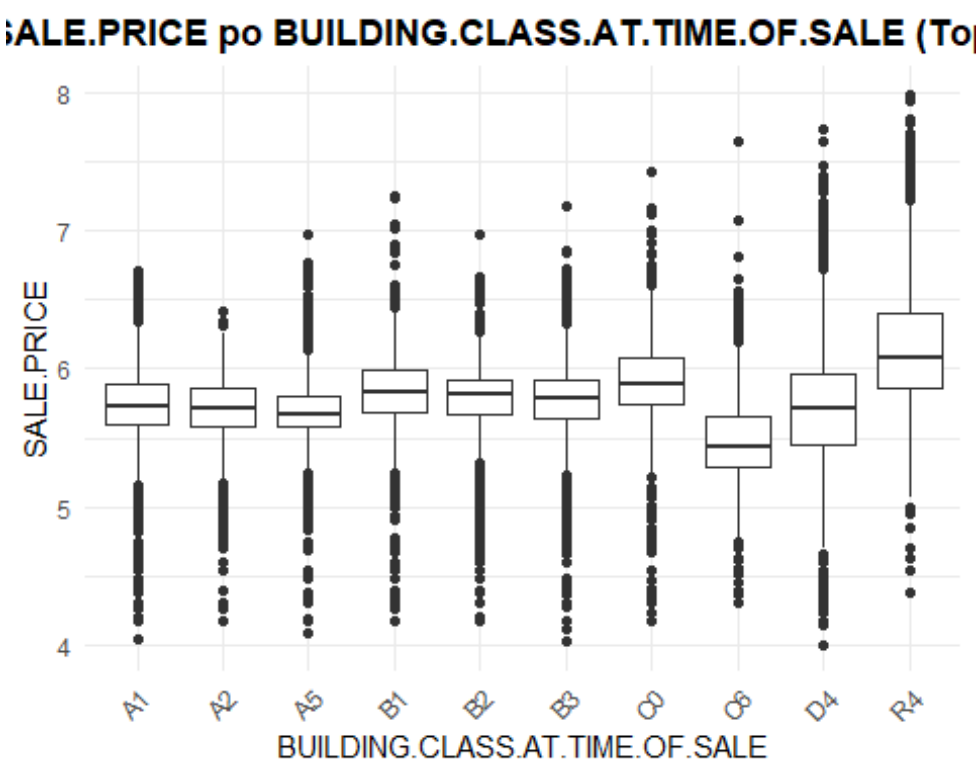

Kao i kod prethodnog grafikona (BUILDING.CLASS.CATEGORY), vide se razlike u medijanama cena između različitih klasa, što znači da tip objekta utiče na cenu. Ova varijabla je detaljnija jer prikazuje tačnu administrativnu klasu u momentu prodaje.

```
data <- data %>%
  mutate(
    starost = as.integer(format(SALE.DATE, "%Y")) - YEAR.BUILT,
    mesec = factor(as.integer(format(SALE.DATE, "%m"))),
    godina = as.factor(format(SALE.DATE, "%Y"))
  )
```

Pošto su varijable starost, mesec i godina povezane, u model se obično uključuje samo jedna zbog moguće kolinearnosti, ali sve tri potvrđuju da karakteristike objekta imaju uticaj na formiranje cene.

Grafik prikazuje broj transakcija po mesecima i može se uočiti da nema značajnih padova i porasta tokom perioda od 12 meseci. Prodaja je relativno stabilna iz meseca u mesec. Iako postoje manje varijacije, ukupan obim prodaje je ujednačen i održava se na približno istom nivou tokom svih 12 meseci.

```
ggplot(data, aes(x = mesec)) +
  geom_bar(alpha = 0.7) +
  labs(
    title = "Broj transakcija po mesecu",
    x = "Mesec",
    y = "Broj prodaja"
  ) +
  theme_minimal()
```

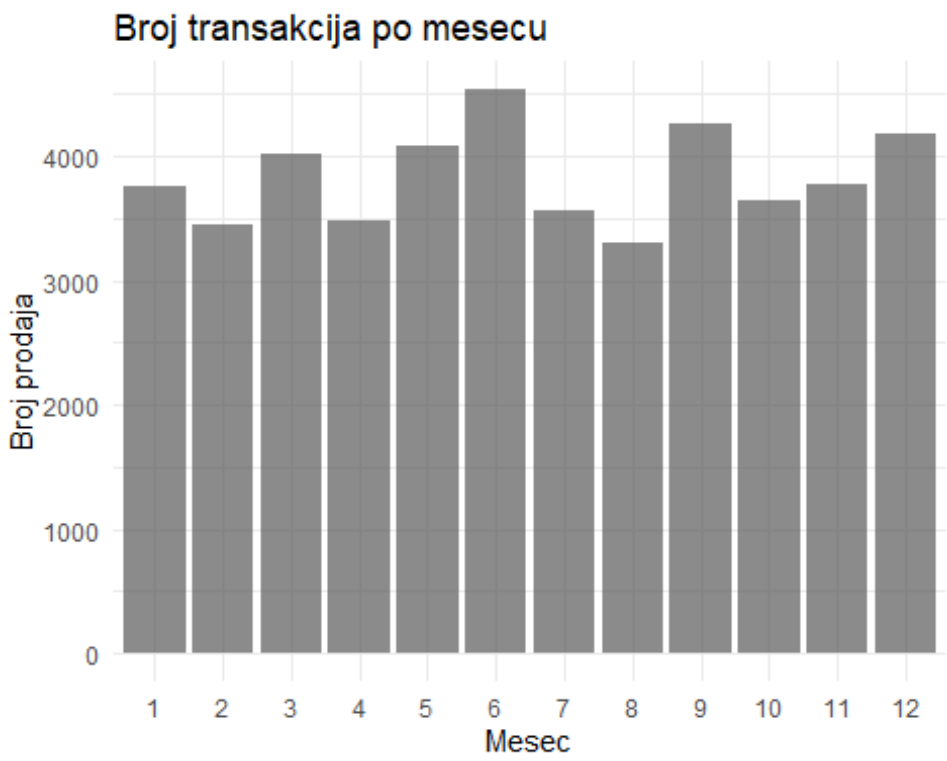

Grafik prikazuje veći broj transakcija u 2017. godini, ali to ne znači da je došlo do porasta prodaje. Razlika je posledica načina prikupljanja podataka. Posmatrani skup obuhvata period od 12 meseci, ali ne od 1. januara do 31. decembra, već od septembra 2016. godine do kraja avgusta 2017. godine. Zbog toga su u 2016. godini evidentirani samo meseci od septembra do decembra, dok 2017. obuhvata period od januara do avgusta. Veći ukupan broj transakcija u 2017. godini rezultat je raspodele perioda posmatranja, a ne stvarnog rasta prodaje.

```
ggplot(data, aes(x = godina)) +
  geom_bar(alpha = 0.7) +
  labs(
    title = "Broj transakcija po godini",
    x = "Godina",
    y = "Broj prodaja"
  ) +
  theme_minimal()
```

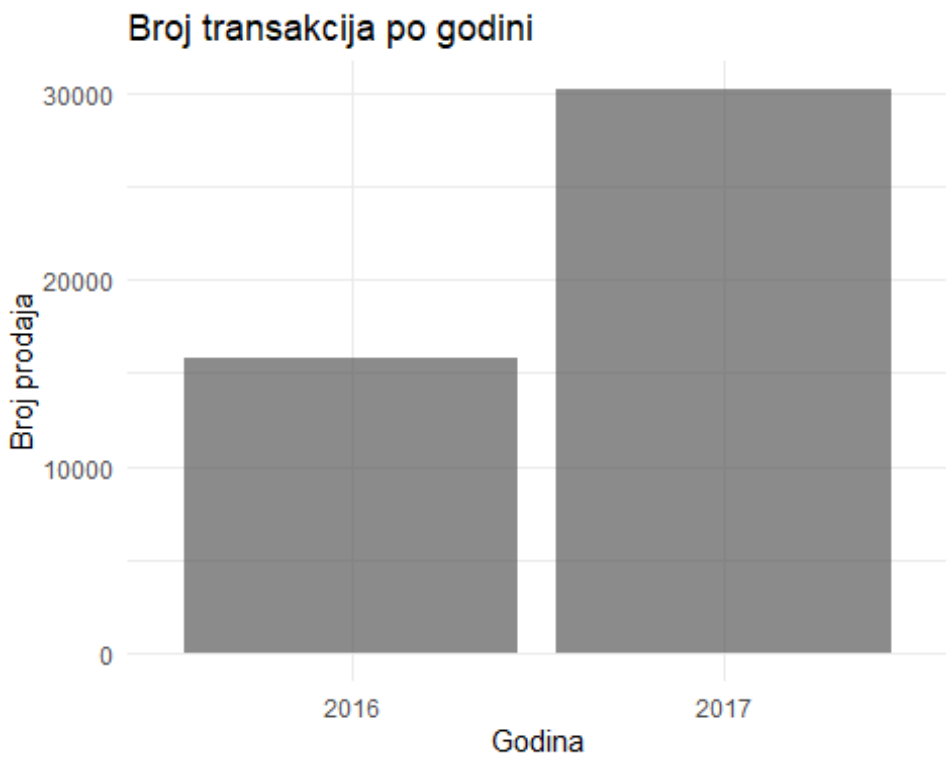

Sada hocemo da proverimo da li starost ima veze sa cenom i pored toga da li se u odredjenim mesecima nekretnine skuplje prodaju. Tako da moramo da dodamo ove dve kolone

```
ggplot(data, aes(x = mesec, y = log_sale_price)) +
  geom_boxplot(outlier_alpha = 0.3) +
  scale_y_continuous(labels = comma) +
  labs(
    title = "SALE.PRICE po mesecu",
    x = "Mesec",
    y = "SALE.PRICE"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    axis.text.x = element_text(angle = 45, hjust = 1)
  )
```

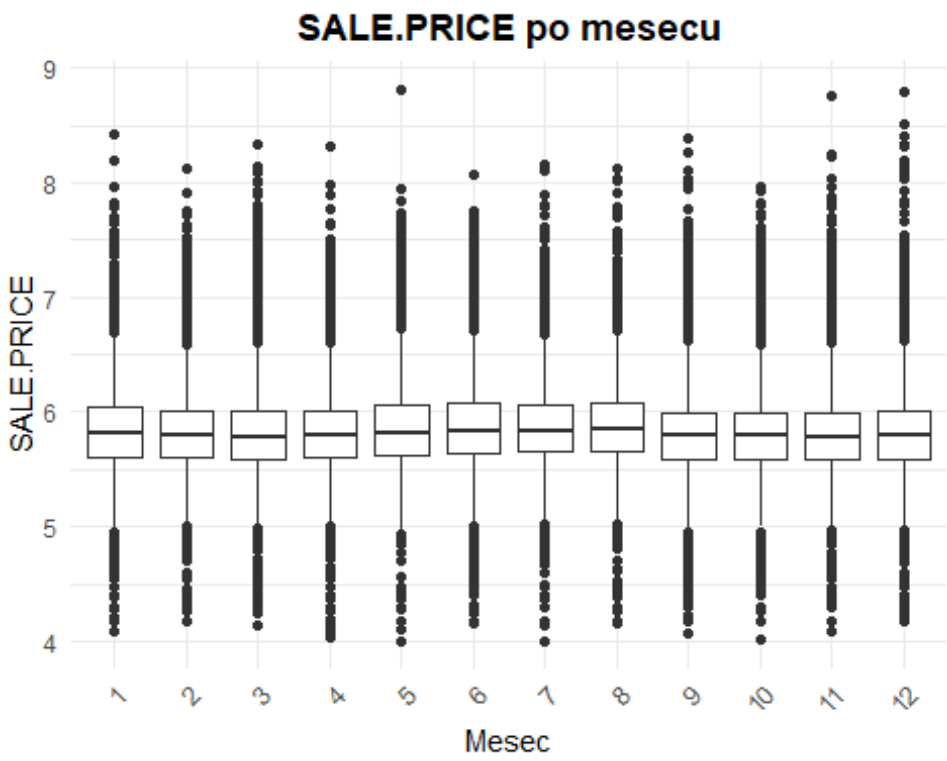

Kao što vidimo nema jake veze izmedju doba godine i cena nekretnina.

```
ggplot(data, aes(x = starost, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  scale_y_continuous(labels = comma) +
  labs(title = "SALE.PRICE po starosti",
       x = "Starost",
       y = "Prodajna cena") +
  theme_minimal()
```

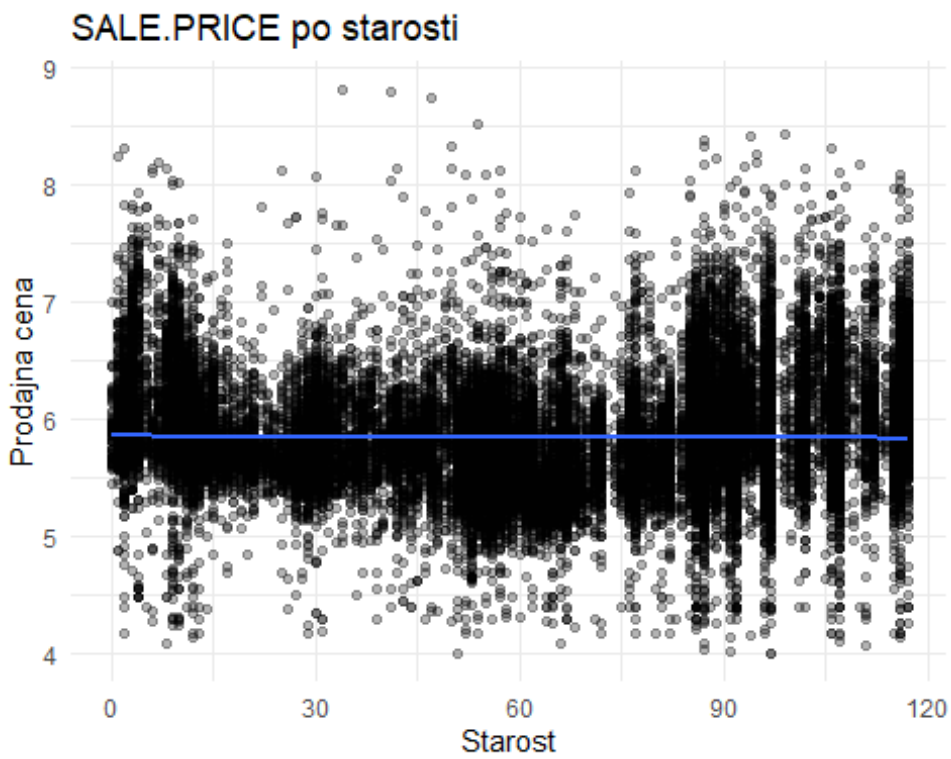

Na scatter grafiku ne uočava se jasna linearna veza između starosti objekta i prodajne cene, jer je regresiona linija gotovo horizontalna, a podaci su izrazito rasuti. To ukazuje da starost sama po sebi nema značajan uticaj na visinu prodajne cene. Ovde smo umesto zumiranja koristili samo log_sale_price.

```
ggplot(data, aes(x = RESIDENTIAL.UNITS, y = SALE.PRICE)) +
  geom_point(alpha = 0.3) +
  coord_cartesian(xlim = c(0, 50),
                  ylim = c(0, 5000000)) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title = "SALE.PRICE po broju stambenih jedinica",
       x = "Broj stambenih jedinica",
       y = "Prodajna cena") +
  theme_minimal()
```

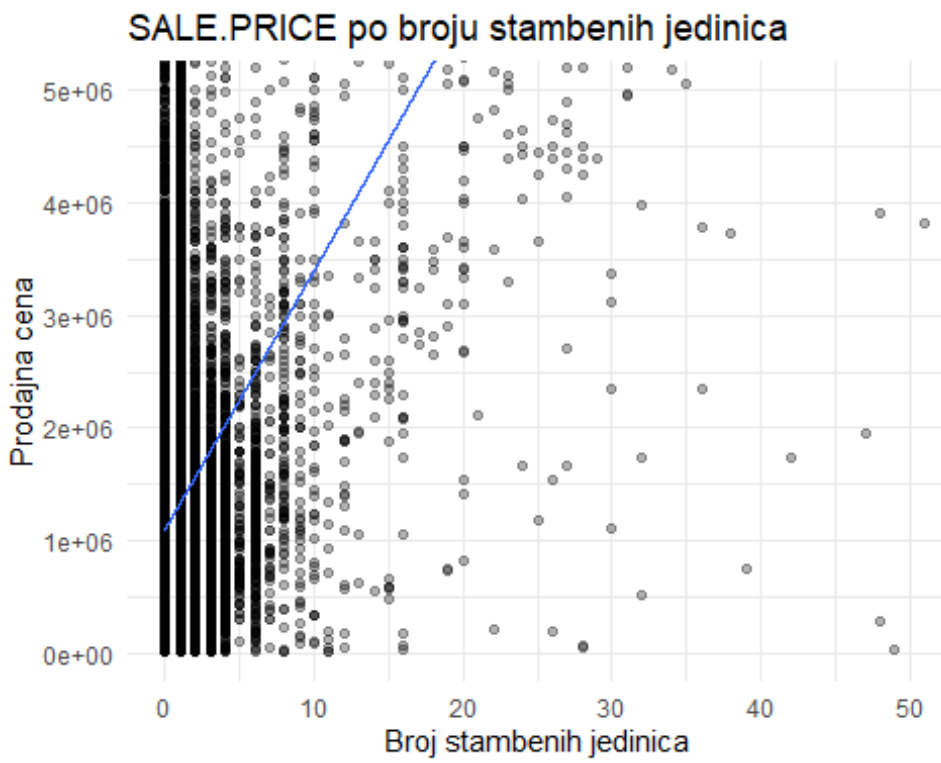


```r
ggplot(data, aes(x = COMMERCIAL.UNITS, y = SALE.PRICE)) +
  geom_point(alpha = 0.3) +
  coord_cartesian(xlim = c(0, 50),
                  ylim = c(0, 5000000)) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title = "SALE.PRICE po broju komercijalnih jedinica",
       x = "Broj komercijalnih jedinica",
       y = "Prodajna cena") +
  theme_minimal()

## `geom_smooth()` using formula = 'y ~ x'
```

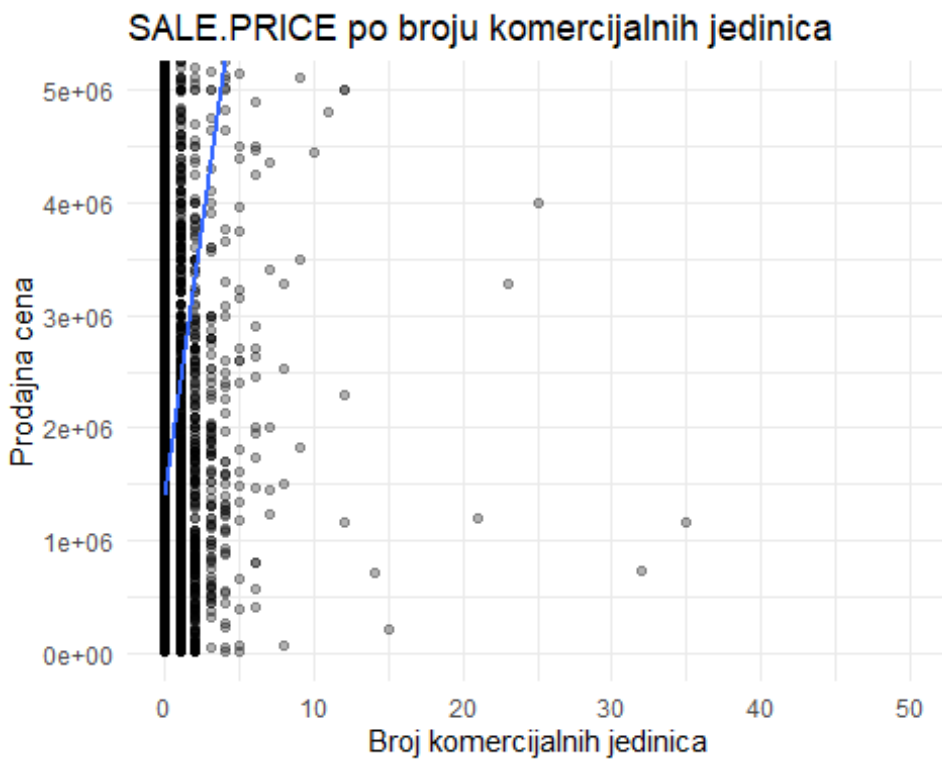


```r
ggplot(data, aes(x = TOTAL.UNITS, y = SALE.PRICE)) +
  geom_point(alpha = 0.3) +
  coord_cartesian(xlim = c(0, 100),
                  ylim = c(0, 5000000)) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title = "SALE.PRICE po ukupnom broju jedinica",
       x = "Ukupan broj jedinica",
       y = "Prodajna cena") +
  theme_minimal()

## `geom_smooth()` using formula = 'y ~ x'
```

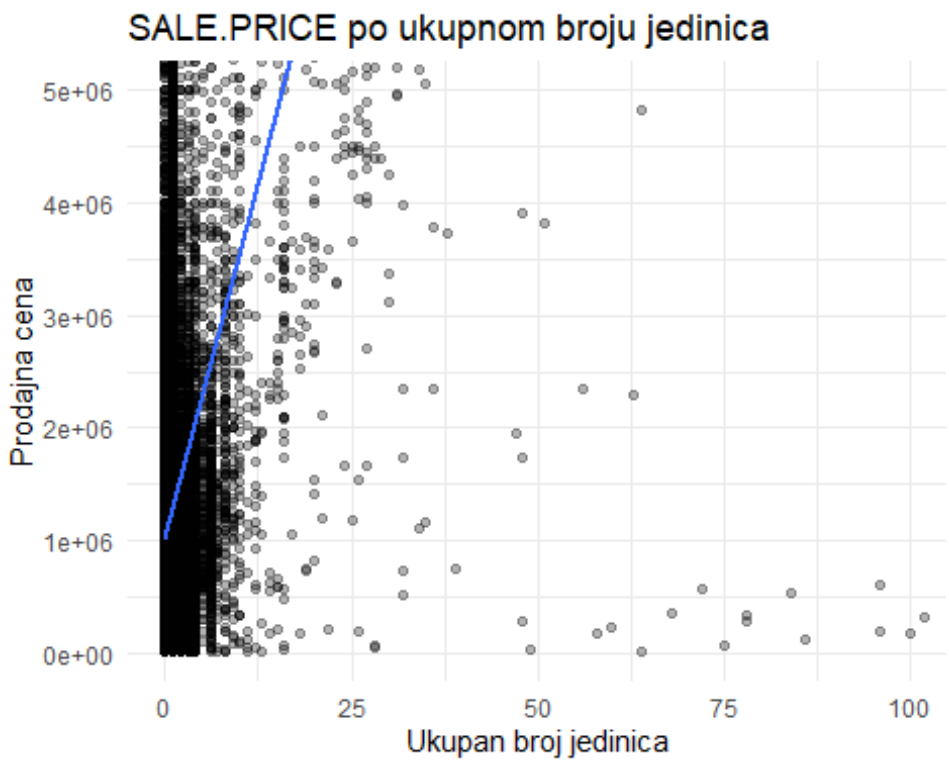

U sva tri slučaja (stambene, ukupne i komercijalne jedinice) vidi se pozitivan odnos sa prodajnom cenom. Najveća koncentracija objekata javlja se kod nižih vrednosti, dok je znatno manji broj objekata zastupljen kod viših vrednosti, što ukazuje na izraženu desnu asimetriju raspodele.

Feature engineering i feature selection

Feature engineering

Tokom EDA smo uočili da promenljiva BUILDING.CLASS.CATEGORY sadrži veliki broj različitih kategorija, od kojih su mnoge retke. Takva promenljiva u linearnom modelu dovodi do velikog broja dummy promenljivih, povećava složenost modela i može izazvati nestabilne predikcije.

Zbog toga smo agregirali BUILDING.CLASS.CATEGORY u manji broj širih grupa (npr. porodične kuće, condos, coops, rentals i ostalo). Ovime smo zadržali najvažniju informaciju o tipu nekretnine, smanjili dimenzionalnost i dobili interpretabilniji i stabilniji model.

```r
#Podrazumevana grupa
data$grupa_nekretnine <- "OTHER"

#Porodicne kuce
data$grupa_nekretnine[grepl("ONE FAMILY", data$BUILDING.CLASS.CATEGORY)]   <-
"ONE_FAMILY"
data$grupa_nekretnine[grepl("TWO FAMILY", data$BUILDING.CLASS.CATEGORY)]   <-
"TWO_FAMILY"
data$grupa_nekretnine[grepl("THREE FAMILY", data$BUILDING.CLASS.CATEGORY)] <-
"THREE_FAMILY"

#Condos i coops
data$grupa_nekretnine[grepl("CONDO", data$BUILDING.CLASS.CATEGORY)] <- "CONDO
"
data$grupa_nekretnine[grepl("COOP",  data$BUILDING.CLASS.CATEGORY)] <- "COOP"
data$grupa_nekretnine[grepl("COOPS", data$BUILDING.CLASS.CATEGORY)] <- "COOP"

#Rentals
data$grupa_nekretnine[grepl("RENTAL",  data$BUILDING.CLASS.CATEGORY)] <- "REN
TAL"
data$grupa_nekretnine[grepl("RENTALS", data$BUILDING.CLASS.CATEGORY)] <- "REN
TAL"

#Commercial (store, office, hotels, warehouses, factories...)
data$grupa_nekretnine[grepl("STORE", data$BUILDING.CLASS.CATEGORY)]      <- "
COMMERCIAL"
data$grupa_nekretnine[grepl("OFFICE", data$BUILDING.CLASS.CATEGORY)]     <- "
COMMERCIAL"
data$grupa_nekretnine[grepl("HOTEL", data$BUILDING.CLASS.CATEGORY)]      <- "
COMMERCIAL"
data$grupa_nekretnine[grepl("WAREHOUSE", data$BUILDING.CLASS.CATEGORY)]  <- "
COMMERCIAL"
data$grupa_nekretnine[grepl("FACTORY", data$BUILDING.CLASS.CATEGORY)]    <- "
COMMERCIAL"
data$grupa_nekretnine[grepl("INDUSTRIAL", data$BUILDING.CLASS.CATEGORY)] <- "
COMMERCIAL"
data$grupa_nekretnine[grepl("COMMERCIAL", data$BUILDING.CLASS.CATEGORY)] <- "
COMMERCIAL"
```

Sada je potrebno da novu kolonu transformišemo u factor i prikazaćemo njenu raspodelu po grupama.

```r
data$grupa_nekretnine <- as.factor(data$grupa_nekretnine)

table(data$grupa_nekretnine)

##
##   COMMERCIAL        CONDO         COOP   ONE_FAMILY        OTHER       REN
TAL
##         1357         7079        11452        12381          335         2
```

```
219
## THREE_FAMILY   TWO_FAMILY
##         2041         9189
```

```r
ggplot(data, aes(x = grupa_nekretnine, y = log_sale_price)) +
  geom_boxplot(alpha = 0.3) +
  labs(
    title = "SALE.PRICE po grupa_nekretnine",
    x = "Grupa nekretnine",
    y = "log SALE.PRICE"
  ) +
  theme_minimal()
```

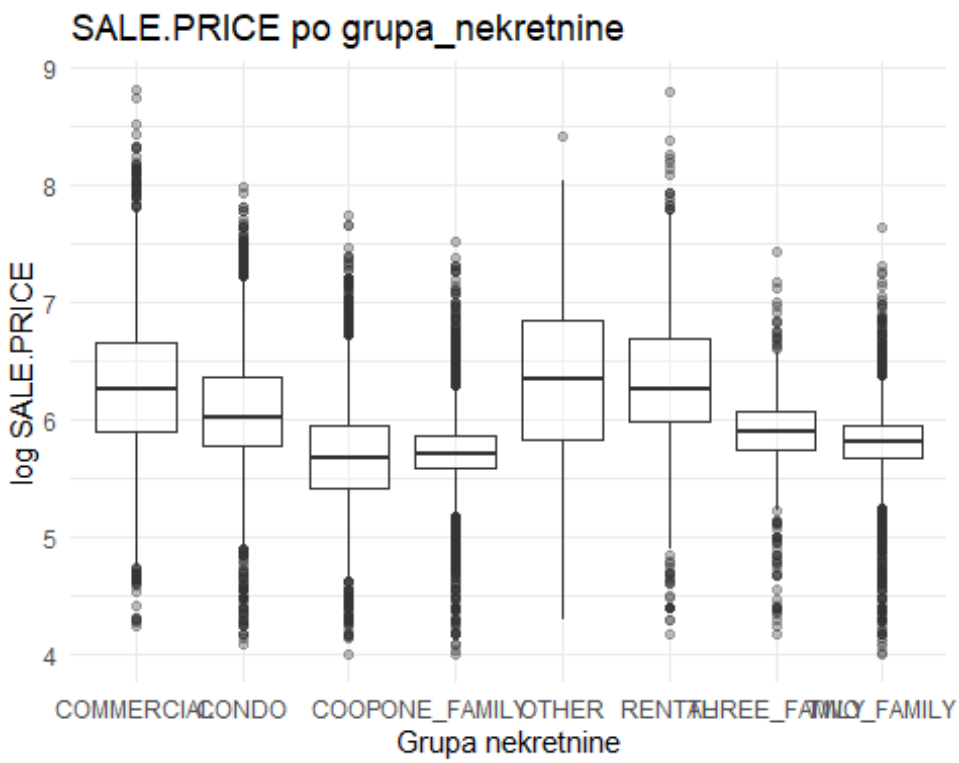


```r
anova_grupan <- aov(log_sale_price ~ grupa_nekretnine, data = data)
summary(anova_grupan)
```

```
##                     Df Sum Sq Mean Sq F value Pr(>F)
## grupa_nekretnine     7   1680  239.97    1648 <2e-16 ***
## Residuals        46045   6706    0.15
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Sa grafika se vidi da postoje razlike u distribuciji prodajne cene između različitih grupa nekretnina. Pojedine grupe imaju višu medijanu cene i širi raspon vrednosti. Prisustvo različitih medijana i interkvartilnih raspona ukazuje da tip nekretnine utiče na formiranje

cene. Rezultati ANOVA testa dodatno potvrđuju da su te razlike statistički značajne, što znači da je promenljiva grupa_nekretnine dobar FA.

Zbog prethodno izvršenih imputacija moraćemo ponovno da izvršimo logaritmovanje promenljivih LAND.SQUARE.FEET i GROSS.SQUARE.FEET.

```
data <- data %>%
  mutate(
    log_gross_sqft = log10(GROSS.SQUARE.FEET + 1),
    log_land_sqft  = log10(LAND.SQUARE.FEET + 1))
```

Uveli smo još dva dodatna feature-a kako bismo poboljšali predikcije našeg linearnog modela. Prvi feature, isk_parcele, predstavlja približnu meru iskorišćenosti parcele (odnos bruto površine objekta i površine zemljišta). Ovaj odnos bolje opisuje cenu nego svaka od ove dve površine zasebno, jer hvata "gustinu" izgradnje (npr. zgrade sa mnogo kvadrata na maloj parceli).

```
data <- data %>%
  mutate(isk_parcele = (GROSS.SQUARE.FEET + 1) / (LAND.SQUARE.FEET + 1))

ggplot(data, aes(x = isk_parcele, y = log_sale_price)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    title = "Odnos iskoriscenosti parcele i prodajne cene",
    x = "Iskoriscenost parcele",
    y = "log SALE.PRICE"
  )

## `geom_smooth()` using formula = 'y ~ x'
```

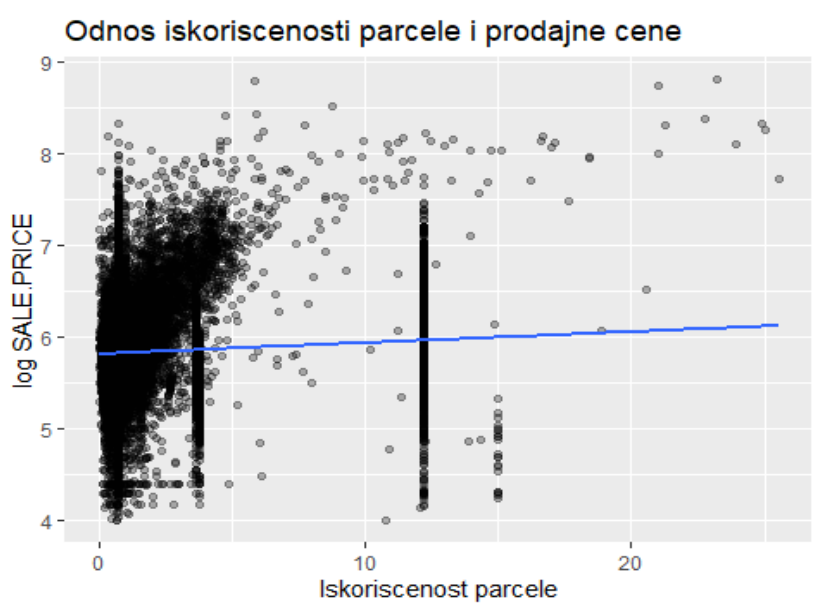

Sa grafika se vidi postojanje obrasca između iskorišćenosti parcele i prodajne cene. Trend linija pokazuje isti smer veze. I bez sprovođenja formalnog statističkog testa, vizuelna analiza pruža dovoljno jak dokaz o postojanju povezanosti. Na grafiku vidimo da je isk_parcele relevantna kolona, pa ne moramo da radimo neki test da bi dokazali to.

Drugi feature, borough_group, predstavlja interakciju između lokacije (BOROUGH) i grupe nekretnine (grupa_nekretnine). Ovim omogućavamo modelu da razlikuje situacije gde ista vrsta nekretnine može imati različitu cenu u različitim opštinama (npr. CONDO u Manhattanu naspram CONDO u Queens-u).

```
data <- data %>%
  mutate(borough_group = interaction(BOROUGH, grupa_nekretnine, drop = TRUE))

ggplot(data, aes(x = borough_group, y = log_sale_price)) +
  geom_boxplot(outlier_alpha = 0.2) +
  labs(
    title = "SALE.PRICE po borough_group",
    x = "BOROUGH × grupa_nekretnine",
    y = "log10(SALE.PRICE)"
  ) +
  theme_minimal()

## Warning in geom_boxplot(outlier_alpha = 0.2): Ignoring unknown parameters:
## `outlier_alpha`
```

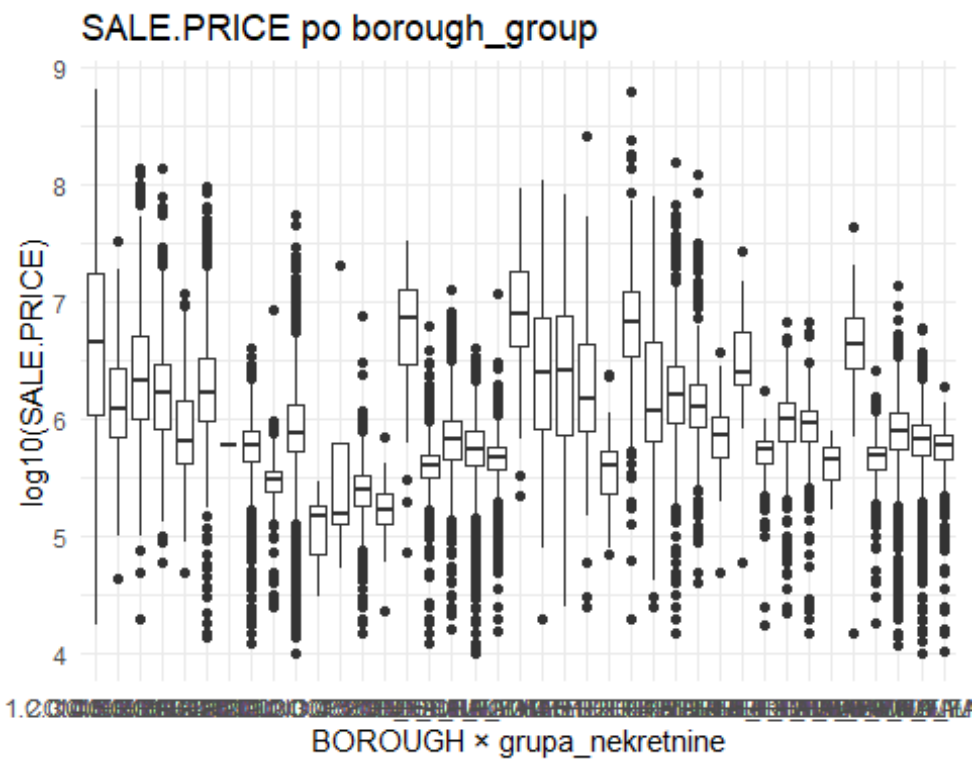


```
anova_bg <- aov(log_sale_price ~ borough_group, data = data)
summary(anova_bg)

##                   Df Sum Sq Mean Sq F value Pr(>F)
## borough_group     38   3529   92.88     880 <2e-16 ***
## Residuals      46014   4857    0.11
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Grafik je prilično prenatrpan zbog velikog broja kategorija, ali se ipak može uočiti da postoje razlike u distribuciji cena između grupa, što ukazuje na potencijalnu relevantnost ove varijable. To možemo statistički potvrditi primenom ANOVA testa.

Tokom univarijantne analize smo pomenuli engineerovanje dva nova feature-a vezana za unit-e: res_units_grupa i ima_komercijalne.

Pošto je RESIDENTIAL.UNITS izrazito desno-asimetričan i većina vrednosti je mala, ovu promenljivu grupišemo u kategorije (0, 1, 2–3, 4+). Time smanjujemo uticaj ekstremnih vrednosti i dobijamo interpretabilniji feature za model.

```
data$res_units_grupa <- NA

data$res_units_grupa[data$RESIDENTIAL.UNITS == 0] <- "0"
data$res_units_grupa[data$RESIDENTIAL.UNITS == 1] <- "1"
```

```r
data$res_units_grupa[data$RESIDENTIAL.UNITS %in% c(2, 3)] <- "2-3"
data$res_units_grupa[data$RESIDENTIAL.UNITS >= 4] <- "4+"

# Faktor transformacija
data$res_units_grupa <- factor(data$res_units_grupa, levels = c("0", "1", "2-
3", "4+"))

ggplot(data, aes(x = res_units_grupa, y = log_sale_price)) +
  geom_boxplot(alpha = 0.6) +
  labs(
    title = "Prodajna cena u odnosu na broj stambenih jedinica",
    x = "Broj stambenih jedinica",
    y = "log SALE.PRICE"
  ) +
  theme_minimal()
```

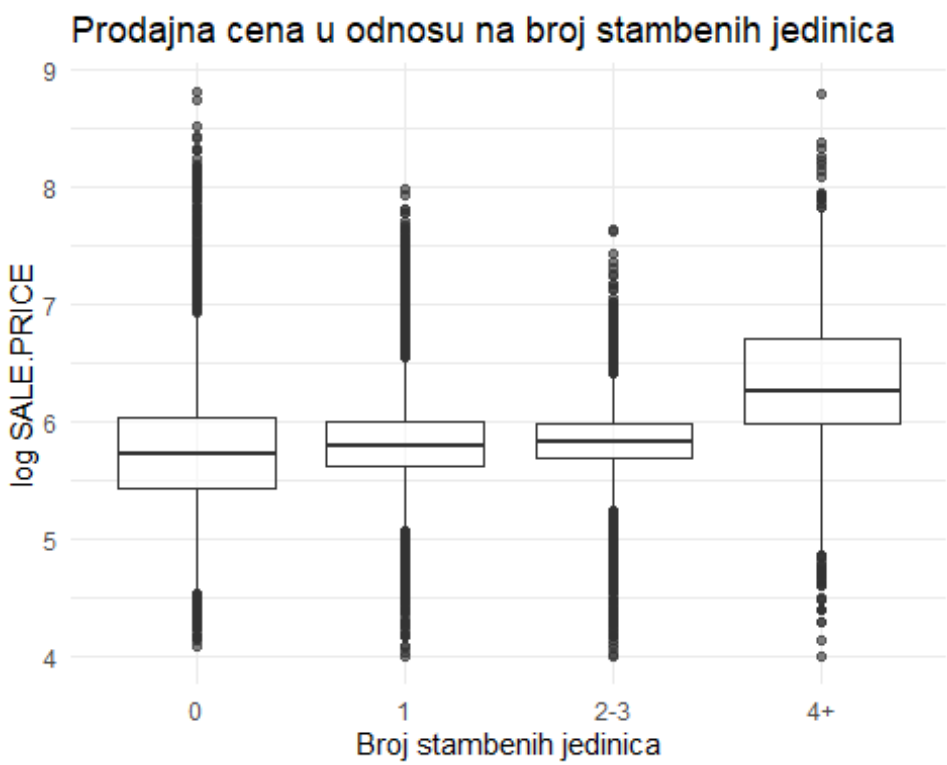

Ovo smo i očekivali da ima povezanosti, jer smo u prethodnoj analizi već uočili da broj stambenih jedinica (RESIDENTIAL.UNITS) ima značajan uticaj na formiranje prodajne cene nekretnine.

Kolona COMMERCIAL.UNITS je najčešće 0, pa je praktičnije koristiti binarni indikator ima_komercijalne (0/1) koji označava da li objekat ima bar jednu komercijalnu jedinicu. Ovaj feature stabilnije hvata razliku između stambenih i komercijalnih objekata.

```r
data$ima_komercijalne <- ifelse(is.na(data$COMMERCIAL.UNITS), 0,
                                ifelse(data$COMMERCIAL.UNITS > 0, 1, 0))
data$ima_komercijalne <- factor(data$ima_komercijalne, levels = c(0, 1))

ggplot(data, aes(x = ima_komercijalne, y = log_sale_price)) +
  geom_boxplot(alpha = 0.6) +
  labs(
    title = "Uticaj komercijalnih jedinica na cenu",
    x = "Ima komercijalne jedinice (0 = Ne, 1 = Da)",
    y = "log SALE.PRICE"
  ) +
  theme_minimal()
```

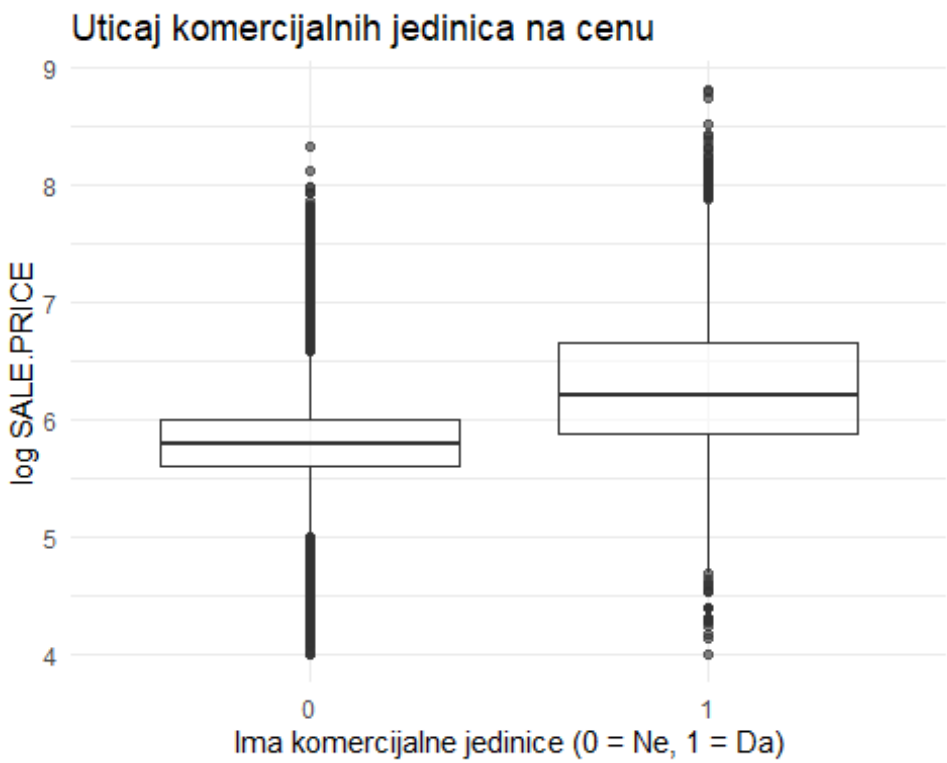

Ovo smo očekivali, budući da smo u prethodnoj analizi već utvrdili da broj komercijalnih jedinica ima povezanost sa SALE.PRICE, pa je logično da i sama prisutnost komercijalnog dela objekta utiče na formiranje njegove vrednosti.

Feature selection

Kao početni skup feature-a uzeli smo promenljive koje imaju jasno značenje u kontekstu nekretnina i za koje je realno očekivati da utiču na cenu: veličina objekta i parcele (GROSS.SQUARE.FEET, LAND.SQUARE.FEET) i njihove logovane vrednosti, broj jedinica

(TOTAL.UNITS, RESIDENTIAL.UNITS, COMMERCIAL.UNITS), lokacija na nivou opštine (BOROUGH) i tip nekretnine kroz agregiranu kategoriju (grupa_nekretnine).

Istovremeno smo izbacili kolone koje bi nepotrebno zakomplikovale model ili uvele šum. To uključuje identifikacione atribute (npr. ADDRESS), kao i kategorijske kolone visoke kardinalnosti poput NEIGHBORHOOD. Ovakve promenljive bi zahtevale veliki broj dummy promenljivih, povećale dimenzionalnost i rizik od overfitting-a.

Varijablu SALE.DATE koju smo ukljucili u analizu kako bismo ispitali eventualne vremenske trendove, nije pokazala značajan uticaj na prodajnu cenu, te smo zaključili da nema dovoljno informativnu vrednost za finalni model.

```
data_fs <- data %>%
  select(
    SALE.PRICE, log_sale_price, GROSS.SQUARE.FEET, log_gross_sqft, LAND.SQUAR
E.FEET, log_land_sqft,
    TOTAL.UNITS, RESIDENTIAL.UNITS, COMMERCIAL.UNITS, BOROUGH,
    grupa_nekretnine, isk_parcele, borough_group
  )
```

Implementacija i procena modela

Pre pravljenja bilo kog modela treba da podelimo naš data set u dve tabele train i test.

```
train_index <- sample(seq_len(nrow(data)), size = 0.8 * nrow(data))
train <- data[train_index, ]
test  <- data[-train_index, ]
```

Prvo ćemo uraditi samo neki najprostiji model koji gleda samo jednu kolonu, kolonu ćemo da izaberemo iz cor tabele.

```
numericki <- train %>%
  select(where(is.numeric))
cor_matrix <- cor(numericki, use = "complete.obs")
round(cor_matrix, 2)

##                    BLOCK   LOT RESIDENTIAL.UNITS COMMERCIAL.UNITS TOTAL.UNI
TS
## BLOCK               1.00 -0.24             -0.02            -0.02       -0.
02
## LOT                -0.24  1.00             -0.04            -0.02       -0.
04
## RESIDENTIAL.UNITS -0.02 -0.04              1.00             0.04        0.
97
## COMMERCIAL.UNITS  -0.02 -0.02              0.04             1.00        0.
```

```
27
## TOTAL.UNITS       -0.02 -0.04              0.97             0.27        1.
00
## LAND.SQUARE.FEET   0.06 -0.13              0.04             0.01        0.
04
## GROSS.SQUARE.FEET -0.28 -0.20              0.10             0.03        0.
10
## YEAR.BUILT        -0.07  0.40             -0.03            -0.01       -0.
03
## SALE.PRICE        -0.10  0.03              0.34             0.29        0.
40
## log_sale_price    -0.31  0.19              0.17             0.12        0.
19
## log_gross_sqft    -0.29 -0.22              0.05             0.03        0.
06
## log_land_sqft     -0.06 -0.21              0.04             0.02        0.
04
## imp_land          -0.43  0.47             -0.12            -0.04       -0.
12
## imp_gross         -0.43  0.46             -0.12            -0.04       -0.
12
## starost            0.07 -0.40              0.03             0.01        0.
03
## isk_parcele       -0.35 -0.18              0.01             0.03        0.
01
##                   LAND.SQUARE.FEET GROSS.SQUARE.FEET YEAR.BUILT SALE.PRICE
## BLOCK                         0.06             -0.28      -0.07      -0.10
## LOT                          -0.13             -0.20       0.40       0.03
## RESIDENTIAL.UNITS             0.04              0.10      -0.03       0.34
## COMMERCIAL.UNITS              0.01              0.03      -0.01       0.29
## TOTAL.UNITS                   0.04              0.10      -0.03       0.40
## LAND.SQUARE.FEET              1.00              0.35       0.00       0.01
## GROSS.SQUARE.FEET             0.35              1.00      -0.06       0.14
## YEAR.BUILT                    0.00             -0.06       1.00       0.01
## SALE.PRICE                    0.01              0.14       0.01       1.00
## log_sale_price               -0.23             -0.04       0.01       0.40
## log_gross_sqft                0.49              0.94      -0.07       0.07
## log_land_sqft                 0.79              0.72      -0.02       0.04
## imp_land                      0.34              0.57       0.26      -0.01
## imp_gross                     0.34              0.57       0.27      -0.01
## starost                       0.00              0.06      -1.00      -0.01
## isk_parcele                   0.07              0.89      -0.10       0.08
##                   log_sale_price log_gross_sqft log_land_sqft imp_land
## BLOCK                      -0.31          -0.29         -0.06    -0.43
## LOT                         0.19          -0.22         -0.21     0.47
## RESIDENTIAL.UNITS           0.17           0.05          0.04    -0.12
## COMMERCIAL.UNITS            0.12           0.03          0.02    -0.04
## TOTAL.UNITS                 0.19           0.06          0.04    -0.12
## LAND.SQUARE.FEET           -0.23           0.49          0.79     0.34
## GROSS.SQUARE.FEET          -0.04           0.94          0.72     0.57
```

```
## YEAR.BUILT                  0.01          -0.07          -0.02     0.26
## SALE.PRICE                  0.40           0.07           0.04    -0.01
## log_sale_price              1.00          -0.02          -0.17     0.02
## log_gross_sqft             -0.02           1.00           0.81     0.59
## log_land_sqft              -0.17           0.81           1.00     0.49
## imp_land                    0.02           0.59           0.49     1.00
## imp_gross                   0.02           0.59           0.49     0.99
## starost                    -0.01           0.07           0.02    -0.26
## isk_parcele                 0.10           0.82           0.44     0.48
##                   imp_gross starost isk_parcele
## BLOCK                 -0.43    0.07       -0.35
## LOT                    0.46   -0.40       -0.18
## RESIDENTIAL.UNITS     -0.12    0.03        0.01
## COMMERCIAL.UNITS      -0.04    0.01        0.03
## TOTAL.UNITS           -0.12    0.03        0.01
## LAND.SQUARE.FEET       0.34    0.00        0.07
## GROSS.SQUARE.FEET      0.57    0.06        0.89
## YEAR.BUILT             0.27   -1.00       -0.10
## SALE.PRICE            -0.01   -0.01        0.08
## log_sale_price         0.02   -0.01        0.10
## log_gross_sqft         0.59    0.07        0.82
## log_land_sqft          0.49    0.02        0.44
## imp_land               0.99   -0.26        0.48
## imp_gross              1.00   -0.27        0.48
## starost               -0.27    1.00        0.10
## isk_parcele            0.48    0.10        1.00
```

Uzimamo logaritmovan GROSS.SQUARE.FEET jer po cor tabeli on je najbolje korelisan sa cenom.

```r
model1 <- lm(log_sale_price ~ log_gross_sqft, data = train)
summary(model1)
```

```
##
## Call:
## lm(formula = log_sale_price ~ log_gross_sqft, data = train)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -1.8515 -0.2413 -0.0403  0.1786  2.9932
##
## Coefficients:
##                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)     5.886201   0.010899 540.055  < 2e-16 ***
## log_gross_sqft -0.010860   0.002886  -3.763 0.000168 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4268 on 36840 degrees of freedom
```

```
## Multiple R-squared:  0.0003842,  Adjusted R-squared:  0.0003571
## F-statistic: 14.16 on 1 and 36840 DF,  p-value: 0.0001682
```

Kao što možemo videti ovaj model nije dobar uopšte tako da ćemo probati da ga unapredimo tako što ćemo dodati ostale relevantne numeričke kolone u korelaciju.

```
#drugi model uzimamo sve numericke koje nismo dobili preko FE

model2 <- lm(
  log_sale_price ~
    log_gross_sqft +
    log_land_sqft +
    TOTAL.UNITS,
  data = train
)
summary(model2)

##
## Call:
## lm(formula = log_sale_price ~ log_gross_sqft + log_land_sqft +
##     TOTAL.UNITS, data = train)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -4.2704 -0.2239 -0.0384  0.1785  2.9830
##
## Coefficients:
##                  Estimate Std. Error t value Pr(>|t|)
## (Intercept)     6.7070137  0.0185702  361.17   <2e-16 ***
## log_gross_sqft  0.1809657  0.0046977   38.52   <2e-16 ***
## log_land_sqft  -0.4249975  0.0081398  -52.21   <2e-16 ***
## TOTAL.UNITS     0.0070908  0.0001884   37.64   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4033 on 36838 degrees of freedom
## Multiple R-squared:  0.1022, Adjusted R-squared:  0.1021
## F-statistic:  1398 on 3 and 36838 DF,  p-value: < 2.2e-16

pred2 <- predict(model2, newdata = test)
rmse(test$log_sale_price, pred2)

## [1] 0.4084238
```

Kao što vidimo model se malo popravio ali metrike i dalje ukazuju na to da nije dobar, probaćemo da ga popravimo tako što ćemo ubaciti kategorijske promenljive i promenljive iz Feature engineering poglavlja.

Pošto koristimo kategorijske promenjljive u linearnoj regresiji trebalo bi da uradimo neki encoding, konkretno za naše to bi bio one hot encoding, ali R sam to radi umesto nas tako da možemo samo da ih dodamo u lm funkciju kao numeričke.

```
#Treci model uzecemo neke od nasih FE vrednosti i probati da dobijemo bolji m
odel
model3 <- lm(
  log_sale_price ~
    isk_parcele * grupa_nekretnine +
    factor(ima_komercijalne) +
    factor(res_units_grupa)
  ,
  data = train
)
summary(model3)

##
## Call:
## lm(formula = log_sale_price ~ isk_parcele * grupa_nekretnine +
##     factor(ima_komercijalne) + factor(res_units_grupa), data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.00395 -0.17919 -0.01119  0.17852  2.24598
##
## Coefficients:
##                                          Estimate Std. Error t value Pr(>
|t|)
## (Intercept)                              6.105200   0.015457 394.991  < 2
e-16
## isk_parcele                              0.058367   0.003296  17.709  < 2
e-16
## grupa_nekretnineCONDO                   -0.358580   0.061759  -5.806 6.45
e-09
## grupa_nekretnineCOOP                    -0.702559   0.016737 -41.977  < 2
e-16
## grupa_nekretnineONE_FAMILY              -0.752635   0.030799 -24.437  < 2
e-16
## grupa_nekretnineOTHER                   -0.144099   0.031324  -4.600 4.23
e-06
## grupa_nekretnineRENTAL                  -0.380123   0.039931  -9.519  < 2
e-16
## grupa_nekretnineTHREE_FAMILY            -0.197546   0.045919  -4.302 1.70
e-05
## grupa_nekretnineTWO_FAMILY              -0.286152   0.039766  -7.196 6.32
e-13
## factor(ima_komercijalne)1                0.091000   0.011756   7.741 1.01
e-14
## factor(res_units_grupa)1                 0.329271   0.027868  11.815  < 2
```

```
e-16
## factor(res_units_grupa)2-3               -0.137711   0.035993  -3.826  0.0
0013
## factor(res_units_grupa)4+                 0.057310   0.036645   1.564  0.1
1784
## isk_parcele:grupa_nekretnineCONDO        -0.052901   0.070570  -0.750  0.4
5349
## isk_parcele:grupa_nekretnineCOOP         -0.015082   0.003381  -4.460 8.21
e-06
## isk_parcele:grupa_nekretnineONE_FAMILY    0.001813   0.009942   0.182  0.8
5532
## isk_parcele:grupa_nekretnineOTHER         0.079687   0.011597   6.872 6.45
e-12
## isk_parcele:grupa_nekretnineRENTAL        0.157313   0.006575  23.926  < 2
e-16
## isk_parcele:grupa_nekretnineTHREE_FAMILY  0.033816   0.019376   1.745  0.0
8096
## isk_parcele:grupa_nekretnineTWO_FAMILY    0.072204   0.010306   7.006 2.50
e-12
##
## (Intercept)                              ***
## isk_parcele                              ***
## grupa_nekretnineCONDO                    ***
## grupa_nekretnineCOOP                     ***
## grupa_nekretnineONE_FAMILY               ***
## grupa_nekretnineOTHER                    ***
## grupa_nekretnineRENTAL                   ***
## grupa_nekretnineTHREE_FAMILY             ***
## grupa_nekretnineTWO_FAMILY               ***
## factor(ima_komercijalne)1                ***
## factor(res_units_grupa)1                 ***
## factor(res_units_grupa)2-3               ***
## factor(res_units_grupa)4+
## isk_parcele:grupa_nekretnineCONDO
## isk_parcele:grupa_nekretnineCOOP         ***
## isk_parcele:grupa_nekretnineONE_FAMILY
## isk_parcele:grupa_nekretnineOTHER        ***
## isk_parcele:grupa_nekretnineRENTAL       ***
## isk_parcele:grupa_nekretnineTHREE_FAMILY .
## isk_parcele:grupa_nekretnineTWO_FAMILY   ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3537 on 36822 degrees of freedom
## Multiple R-squared:   0.31,  Adjusted R-squared:  0.3096
## F-statistic: 870.5 on 19 and 36822 DF,  p-value: < 2.2e-16
```

```r
pred3 <- predict(model3, newdata = test)
rmse(test$log_sale_price, pred3)
```

```
## [1] 0.3566092

#Model koji se najbolje pokazao

model4 <- lm(
  log_sale_price ~
    log_gross_sqft * BOROUGH +
    log_land_sqft +
    factor(ima_komercijalne) +
    factor(res_units_grupa) +
    factor(BUILDING.CLASS.CATEGORY),
  data = train
)

pred4 <- predict(model4, newdata = test)
#Metrike najboljeg modela
rmse(test$log_sale_price, pred4)

## [1] 0.296491

mae(test$log_sale_price, pred4)

## [1] 0.205712

summary(model4)
```

```
##
## Call:
## lm(formula = log_sale_price ~ log_gross_sqft * BOROUGH + log_land_sqft +
##     factor(ima_komercijalne) + factor(res_units_grupa) +
factor(BUILDING.CLASS.CATEGORY),
##     data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.29345 -0.14443  0.01198  0.15249  2.07971
##
## Coefficients:
##
Estimate
## (Intercept)
4.892341
## log_gross_sqft
0.465477...
```

Ovaj model je prihvatljiv i nije najbolji, ali u odnosu na modele od drugih ljudi sa Kaggle platforme koji su isto analizirali ovaj data set on je korektan. Probaćemo još neke modele.

Ridge i lasso

```
#ridge i lasso

data_pomocna_regularizacija  <- data_fs %>%
  select(
    log_sale_price, log_gross_sqft, BUILDING.CLASS.CATEGORY ,log_land_sqft,
    RESIDENTIAL.UNITS, COMMERCIAL.UNITS, BOROUGH
  )

data_pomocna_regularizacija <- drop_na(data_pomocna_regularizacija)

train <- data_pomocna_regularizacija[train_index, ]
test  <- data_pomocna_regularizacija[-train_index, ]

x_train <- model.matrix(log_sale_price ~ ., data = train)[, -1]
y_train <- train$log_sale_price

x_test <- model.matrix(log_sale_price ~ ., data = test)[, -1]
x_test <- x_test[, colnames(x_train)]
y_test <- test$log_sale_price

ridge_cv <- cv.glmnet(x_train, y_train, alpha = 0)
lasso_cv <- cv.glmnet(x_train, y_train, alpha = 1)

ridge_cv$lambda.min

## [1] 0.0122049

lasso_cv$lambda.min

## [1] 0.0001651381

ridge_preds = predict(ridge_cv, newx = x_test, s = "lambda.min")
lasso_preds = predict(lasso_cv, newx = x_test, s = "lambda.min")

rmse(y_test, lasso_preds)

## [1] 0.3005816

mae(y_test, lasso_preds)

## [1] 0.2070594

tss <- sum((y_test - mean(y_test))^2)
rss_lasso <- sum((y_test - lasso_preds)^2)
r2_lasso <- 1 - rss_lasso/tss
r2_lasso

## [1] 0.5136625
```

```r
rmse(y_test, ridge_preds)

## [1] 0.3278716

mae(y_test, ridge_preds)

## [1] 0.2143128

rss_ridge <- sum((y_test - ridge_preds)^2)
r2_ridge <- 1 - rss_ridge/tss
r2_ridge

## [1] 0.4213439
```

Random forest

```r
#random forest
data_rf <- data_pomocna_regularizacija

train <- data_rf[train_index, ]
test  <- data_rf[-train_index, ]
dummies <- dummyVars(~ ., data = train[, !names(train) %in% "log_sale_price"]
)

data.train.num <- data.frame(predict(dummies, newdata = train))
data.train.num$log_sale_price <- train$log_sale_price

data.test.num <- data.frame(predict(dummies, newdata = test))
data.test.num$log_sale_price <- test$log_sale_price

rf_model <- randomForest(
  log_sale_price ~ .,
  data = data.train.num,
  ntree = 500,
  mtry = 3,
  importance = TRUE
)

rf_preds <- predict(rf_model, newdata = data.test.num)

rmse_val <- rmse(data.test.num$log_sale_price, rf_preds)
mae_val  <- mae(data.test.num$log_sale_price, rf_preds)
rmse_val

## [1] 0.3228756

mae_val

## [1] 0.2242845
```

```
rss_rf <- sum((data.test.num$log_sale_price - rf_preds)^2)
tss_rf <- sum((data.test.num$log_sale_price -
                mean(data.test.num$log_sale_price))^2)

r2_rf <- 1 - rss_rf/tss_rf
r2_rf

## [1] 0.4388442
```

Zaključak

Model	RMSE	MAE	R^2
LM – model4	0.2956	0.2060	0.5182
Lasso	0.2960	0.2064	0.5208
Ridge	0.3036	0.2117	0.4961
Random Forest	0.3200	0.2223	0.4401

Na osnovu poređenja četiri modela na test skupu (RMSE, MAE i R^2), najbolji rezultat daju linearna regresija sa interakcijom log_gross_sqft * BOROUGH + log_land_sqft + ima_komercijalne + res_units_grupa + BUILDING.CLASS.CATEGORY (model4) i Lasso regresija, pri čemu su njihove greške praktično iste (RMSE ≈ 0.296, MAE ≈ 0.206), a i objašnjena varijansa je oko ~0.52. Ridge je nešto slabiji (veći RMSE/MAE i niži R^2), dok je Random Forest u korišćenoj konfiguraciji pokazao najlošije performanse, što verovatno znači da je potrebna dodatna optimizacija hiperparametara ili bogatiji skup prediktora. Zaključno, za ovaj dataset i izabrane feature, Lasso i pažljivo definisan linearni model sa interakcijama predstavljaju najbolji kompromis između tačnosti i interpretabilnosti.